ΠΑΝΕΠΙΣΤΗΜΙΟ ΠΑΤΡΩΝ



AIDS Clinical Trials Group Study 175

Συγγραφέας:
Κωνσταντίνος-Αλέξανδρος Σκαρογιάννης-Σπυρόπουλος 1073387

Διδάσκων:
Σωτήριος Κωτσιαντής

Μηχανική Μάθηση
Υπολογιστική & Στατιστική Αναλυτική στην Επιστήμη των Δεδομένων, MCDA
Τμήμα Μαθηματικών

Πάτρα, 2026

Περίληψη

Αντικείμενο της παρούσας εργασίας αποτελεί η ανάπτυξη, η αξιολόγηση και η ερμηνεία μοντέλων μηχανικής μάθησης για την πρόβλεψη της ανοσολογικής απόκρισης σε ασθενείς με τη λοίμωξη HIV. Χρησιμοποιώντας δεδομένα από την κλινική δοκιμή ACTG 175, η οποία περιλαμβάνει 2.139 ασθενείς, επικεντρωθήκαμε στην πρόβλεψη του αριθμού των κυττάρων CD4 μετά από 20 εβδομάδες θεραπευτικής αγωγής. Η μεταβλητή αυτή συνιστά κρίσιμο βιοδείκτη για την παρακολούθηση της εξέλιξης της νόσου και την αξιολόγηση της αποτελεσματικότητας των αντιρετροϊκών σχημάτων. Η μεθοδολογική μας προσέγγιση βασίστηκε στη δημιουργία ενός ολοκληρωμένου pipeline προεπεξεργασίας, διασφαλίζοντας την αποφυγή data leakage και την αναπαραγωγιμότητα των πειραμάτων. Για τη μείωση της διαστατικότητας, εφαρμόσαμε τη μέθοδο Recursive Feature Elimination (RFE), επιλέγοντας στρατηγικά τις δέκα πλέον πληροφοριακές μεταβλητές βάσει της αρχής των φθινουσών αποδόσεων. Στο στάδιο της μοντελοποίησης, πραγματοποιήσαμε συγκριτική ανάλυση μεταξύ παραμετρικών μοντέλων (Γραμμική Παλινδρόμηση) και σύνθετων αλγορίθμων ενίσχυσης δέντρων (Gradient Boosting). Τα αποτελέσματα ανέδειξαν την υπεροχή του μοντέλου Gradient Boosting σε όρους προβλεπτικής ακρίβειας, καθώς κατόρθωσε να μοντελοποιήσει επιτυχώς τις μη γραμμικές αλληλεπιδράσεις των κλινικών χαρακτηριστικών. Προκειμένου να διασφαλίσουμε τη διαφάνεια του μοντέλου και να ενισχύσουμε την κλινική εμπιστοσύνη, χρησιμοποιήσαμε το πλαίσιο των τιμών SHAP (SHAP values). Η ανάλυση μέσω SHAP Summary και Bar Plots αποκάλυψε ότι ο αρχικός αριθμός κυττάρων CD4, το ιστορικό προηγούμενων θεραπειών και το είδος της τρέχουσας αγωγής αποτελούν τους ισχυρότερους προγνωστικούς παράγοντες.

Εισαγωγή

Το σύνολο δεδομένων που θα αναλύσουμε προέρχεται από την κλινική δοκιμή ACTG 175 (AIDS Clinical Trials Group Study 175) η οποία δημοσιεύτηκε το 1996. Πρόκειται για μια τυχαιοποιημένη κλινική μελέτη σε 2139 ενήλικες ασθενείς στις Ηνωμένες Πολιτείες Αμερικής με HIV, οι οποίοι κατά την έναρξη είχαν αριθμό CD4 κυττάρων μεταξύ 200 και 500 ανά mm^3. Στόχος της μελέτης ήταν η σύγκριση της αποτελεσματικότητας της μονοθεραπείας (Zidovudine) έναντι συνδυαστικών αντιρετροϊκών θεραπειών. Η συγκεκριμένη έρευνα δεν είχε μόνο τεράστιο ιατρικό αλλά και βαθύ κοινωνικό αντίκτυπο. Στα μέσα της δεκαετίας του 1990, η επιδημία του HIV/AIDS βρισκόταν σε έξαρση, πλήττοντας δυσανάλογα ευάλωτες και περιθωριοποιημένες ομάδες (όπως η ΛΟΑΤΚΙ+ κοινότητα και οι χρήστες ενδοφλέβιων ναρκωτικών), υπό το βάρος ενός έντονου κοινωνικού στίγματος. Μέχρι τότε, η μονοθεραπεία αποτελούσε το κύριο όπλο αλλά η γρήγορη ανάπτυξη ανθεκτικότητας από τον ιό οδηγούσε σε υψηλά ποσοστά θνησιμότητας. Η μελέτη ACTG 175 υπήρξε καθοριστική καθώς απέδειξε επιστημονικά ότι η συνδυαστική αγωγή μπορούσε να παρατείνει σημαντικά τη ζωή των ασθενών, ανοίγοντας τον δρόμο για τις σύγχρονες θεραπείες (HAART) που μετέτρεψαν το AIDS σε μια διαχειρίσιμη χρόνια νόσο.
Τα δεδομένα αντλήθηκαν από το UCI Machine Learning Repository
(σύνδεσμος: https://archive.ics.uci.edu/dataset/890/aids+clinical+trials+group+study+175).
Και το paper: A trial comparing nucleoside monotherapy with combination therapy in HIV-infected adults with CD4 cell counts from 200 to 500 per cubic millimeter. AIDS Clinical Trials Group Study 175 Study Team.
Το σύνολο δεδομένων αποτελείται από 2.139 γραμμές (αντιστοιχούν σε ισάριθμους ασθενείς) και 25 στήλες (χαρακτηριστικά), οι οποίες περιλαμβάνουν δημογραφικά στοιχεία, ιατρικό ιστορικό και εργαστηριακές μετρήσεις. Ως μεταβλητή στόχο (target variable) ορίσαμε τη μεταβλητή cd420, η οποία αναπαριστά τον αριθμό των κυττάρων CD4 στο αίμα του ασθενούς μετά από 20 εβδομάδες (με απόκλιση $\pm$ 5 εβδομάδων) από την έναρξη της θεραπείας.

Η μοντελοποίηση της συγκεκριμένης μεταβλητής παρουσιάζει κλινικό ενδιαφέρον για την ιατρική κοινότητα. Ο αριθμός των CD4 κυττάρων (Τ-λεμφοκύτταρα) αποτελεί τον κύριο βιοδείκτη για την αξιολόγηση της κατάστασης του ανοσοποιητικού συστήματος και την παρακολούθηση της εξέλιξης της λοίμωξης HIV.

Η ανάπτυξη ενός ακριβούς μοντέλου μηχανικής μάθησης που μπορεί να προβλέψει την ανοσολογική απόκριση του ασθενούς μετά από ένα συγκεκριμένο χρονικό διάστημα θεραπείας είναι κρίσιμη για δύο λόγους: Επιτρέπει στους ιατρούς να προβλέψουν εάν ένα συγκεκριμένο θεραπευτικό σχήμα (π.χ. μονοθεραπεία vs συνδυαστική θεραπεία) θα επιφέρει την επιθυμητή ανοσολογική ανασύσταση. Καθιστά δυνατή την έγκαιρη αναγνώριση ασθενών που διατρέχουν υψηλό κίνδυνο ανοσολογικής αποτυχίας, επιτρέποντας την τροποποίηση της αγωγής πριν την εμφάνιση ευκαιριακών λοιμώξεων.

Συμπερασματικά, το πρόβλημα που μοντελοποιούμε δεν αποτελεί απλώς μια άσκηση παλινδρόμησης αλλά μια προσπάθεια δημιουργίας ενός υποστηρικτικού εργαλείου για τη λήψη κλινικών αποφάσεων, με στόχο τη βελτίωση της ποιότητας ζωής και της επιβίωσης των ασθενών.
Στο σημειο αυτό θα αναλύσουμε τις μεταβλητές μας. Έχουμε συνολικα 25 μεταβλητές, για πιο εύκολη ανάγνωση θα τις ομαδοποιήσουμε.
Θα ξεκινήσουμε αρχικά με τις μεταβλητές περιγράφουν το προφίλ του ασθενούς κατά την είσοδό του στη μελέτη.

- pidnum: Το id του ασθενούς.
- age: Η ηλικία του ασθενούς σε έτη κατά την εναρξη της έρευνας.
- wtkg: Το βάρος του ασθενούς σε κιλά κατά την έναρξη της έρευνας.
- gender: Το φύλο του ασθενούς (0 = Γυναίκα, 1 = Άνδρας).
- race: Η φυλή (0 = Λευκός, 1 = Μη-Λευκός).
- homo: Ομοφυλοφιλική δραστηριότητα (0 = Όχι, 1 = Ναι).
- drugs: Ιστορικό χρήσης ενδοφλέβιων ναρκωτικών (0 = Όχι, 1 = Ναι).

- hemo: Αιμορροφιλία (0 = Όχι, 1 = Ναι). Πολλοί αιμορροφιλικοί είχαν κολλήσει HIV από μολυσμένες μεταγγίσεις αίματος.

Στη συνέχεια θα αναλύσουμε την κλινική εικόνα των ασθενών κατά την έναρξη της μελέτης.

- karnof: Το σκορ στην Κλίμακα Karnofsky (από 0 έως 100). Αξιολογεί την ικανότητα του ασθενούς να εκτελεί καθημερινές εργασίες. Το 100 σημαίνει τέλεια λειτουργικότητα.
- symptom: Συμπτωματική κατάσταση (0 = Ασυμπτωματικός, 1 = Συμπτωματικός). Δείχνει αν ο ασθενής είχε ήδη εμφανίσει συμπτώματα.

Ακόμη, στο data set περιέχονται πληροφορίες για τη φαρμακευτική αγωγή που ακολουθούσε και αν ακολουθούσε ο ασθενής πριν την είσοδό του στη μελέτη. Συγκεκριμένα:

- str2: Ιστορικό αντιρετροϊκής θεραπείας (0 = Naive / Δεν είχαν πάρει ποτέ φάρμακα, 1 = Experienced / Είχαν πάρει στο παρελθόν).
- strat: Είναι ένα πιο αναλυτικό ιστορικό καθώς δημιουργεί ένα διάστημα.(1 = Naive/ δεν είχαν λάβει αντιρετροικη θεραπεία, 2 = Είχαν από 1 έως 52 εβδομάδες, 3 = Είχαν για πάνω από 52 εβδομάδες).
- preanti: Ο ακριβής αριθμός ημερών που ο ασθενής λάμβανε αντιρετροϊκή θεραπεία πριν ξεκινήσει η κλινική δοκιμή.
- zprior: Αν είχε πάρει ποτέ στο παρελθόν Ζιδοβουδίνη (ZDV) (0 = Όχι, 1 = Ναι).
- z30: Αν είχε πάρει Ζιδοβουδίνη τις τελευταίες 30 ημέρες πριν μπει στη μελέτη (0 = Όχι, 1 = Ναι).
- oprior: Αν είχε πάρει άλλη θεραπεία (εκτός ZDV) πριν τη μελέτη (0 = Όχι, 1 = Ναι).

Θα επεξηγήσουμε τώρα ίσως το πιο σημαντικό κομμάτι του πειράματος, αυτό της θεραπείας.

- treat: Η βασική δυαδική μεταβλητή της θεραπείας (0 = Μονοθεραπεία με Zidovudine, 1 = Συνδυαστική θεραπεία).
- trt: Η ακριβής θεραπευτική ομάδα (0 = ZDV μόνο, 1 = ZDV + ddI, 2 = ZDV + ddC, 3 = ddI μόνο).
- offtrt: Αν ο ασθενής βγήκε εκτός θεραπείας πριν τις 96+5 εβδομάδες (0 = Όχι, 1 = Ναι).

Ανοσολογικοί Δείκτες (Οι εξετάσεις αίματος). Ένας υγιής άνθρωπος έχει 500 έως 1.500 CD4 ανά κυβικό χιλιοστό αίματος. Αν τα CD4 πέσουν κάτω από 200, ο ασθενής θεωρείται ότι έχει μπει επίσημα στο στάδιο του AIDS, καθώς το ανοσοποιητικό του έχει καταρρεύσει και κινδυνεύει να πεθάνει από μια απλή λοίμωξη (Centers for Disease Control and Prevention, 1992; World Health Organization, 2025).

- cd40: Ο αριθμός των CD4 κυττάρων κατά την είσοδο τους στην έρευνα.
- cd420: Ο αριθμός των CD4 κυττάρων μετά από 20+/-5 εβδομάδες.
- cd80: Ο αριθμός των CD8 κυττάρων κατά την είσοδό τους στο πρόγραμμα
- cd820: Ο αριθμός των CD8 κυττάρων μετά από 20+/-5 εβδομάδες.

Τέλος, έχουμε τις μεταβλητές απόκρισης.

- time: Ο χρόνος (σε ημέρες) μέχρι να συμβεί το γεγονός ή μέχρι την αποκοπή (censoring).
- label: Ο δείκτης γεγονότος (1 = Το γεγονός συνέβη, δηλαδή σημαντική πτώση CD4, AIDS ή θάνατος. 0 = Censored, δηλαδή ο ασθενής επιβίωσε χωρίς γεγονός μέχρι το τέλος της παρακολούθησής του).

1 Αρχική διερεύνηση των δεδομένων

1.1 Το πρόβλημα παλινδρόμησης

Σκοπός μας είναι η πρόβλεψη του αριθμού των Τ-λεμφοκυττάρων CD4 ενός ασθενούς με HIV, έπειτα από περίπου 20 εβδομάδες αντιρετροϊκής θεραπείας(20 ± 5). Ο αριθμός των κυττάρων CD4 αποτελεί τον σημαντικότερο βιοδείκτη για την αξιολόγηση της κατάστασης του ανοσοποιητικού συστήματος. Εφόσον η μεταβλητή που θέλουμε να προβλέψουμε λαμβάνει συνεχείς αριθμητικές τιμές (μετρήσεις κυττάρων), η χρήση αλγορίθμων παλινδρόμησης είναι η πλέον ενδεδειγμένη προσέγγιση για την έγκαιρη εκτίμηση της πορείας της υγείας του ασθενούς.

1.2 Συνοπτική παρουσίαση των χαρακτηριστικών εισόδου και της μεταβλητής στόχου

Ως μεταβλητή στόχο ορίσαμε τη μεταβλητή cd420, η οποία εκφράζει τον αριθμό των κυττάρων CD4 στις 20 (±5) εβδομάδες μετά την έναρξη της θεραπείας.

Χαρακτηριστικά Εισόδου: Προκειμένου να αποφύγουμε τη διαρροή δεδομένων (data leakage), αφαιρέσαμε μεταβλητές που αφορούν γεγονότα τα οποία συμβαίνουν μετά τις 20 εβδομάδες (όπως time, days, cid). Τα χαρακτηριστικά εισόδου που διατηρήσαμε κατηγοριοποιούνται ως εξής:

Δημογραφικά : age (ηλικία), wtkg (βάρος σε κιλά), gender (φύλο), race (φυλή).

Ιστορικό : hemo (αιμορροφιλία), homo (ομοφυλοφιλική δραστηριότητα), drugs (χρήση ενδοφλέβιων ναρκωτικών), symptom (συμπτωματική κατάσταση).

Αρχικές κλινικές μετρήσεις (Baseline): cd40 (αρχικά CD4 στο χρόνο 0), cd80 (αρχικά CD8), karnof (δείκτης απόδοσης Karnofsky).

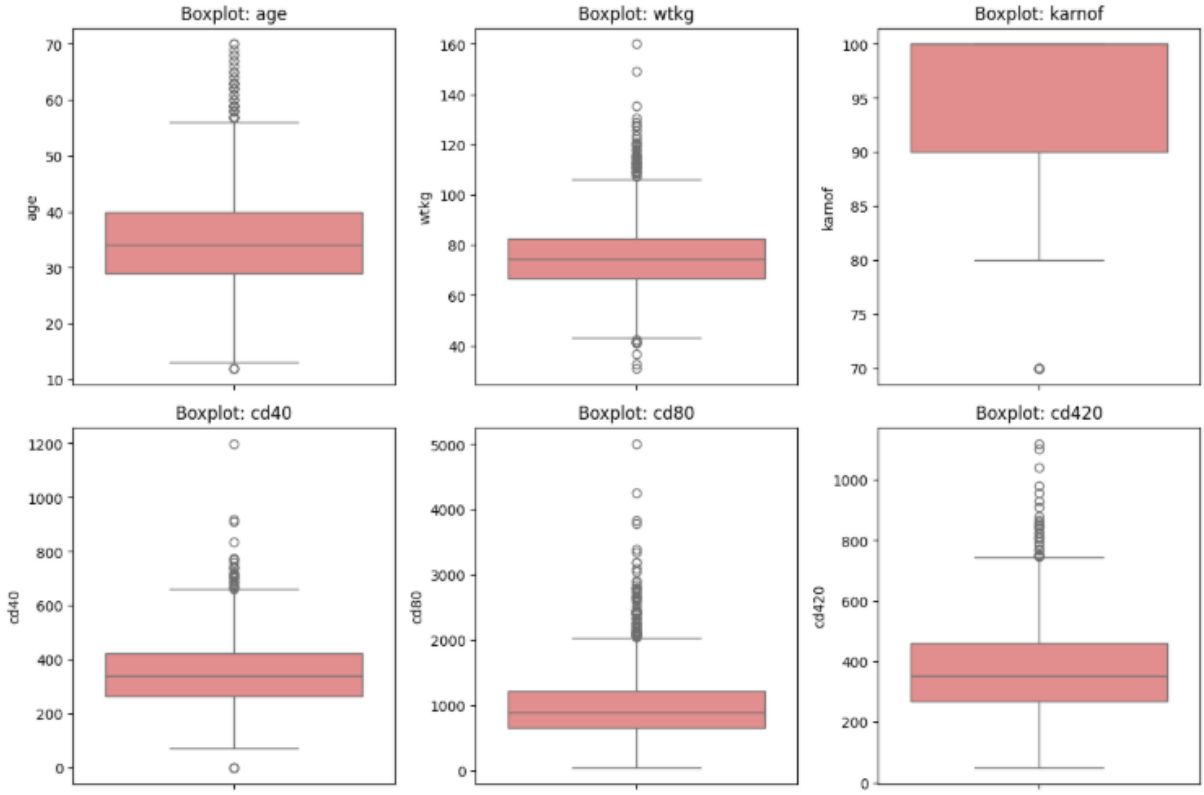
Θεραπεία: trt (το είδος της αντιρετροϊκής αγωγής που χορηγήθηκε).

1.3 Έλεγχος και διαχείριση ελλιπών τιμών

Πραγματοποιήσαμε έλεγχο στο σύνολο δεδομένων με τη χρήση της συνάρτησης isnull().sum() της βιβλιοθήκης pandas. Διαπιστώσαμε ότι δεν υπάρχουν ελλιπείς τιμές σε καμία από τις στήλες του dataset. Συνεπώς, δεν χρειάστηκε να εφαρμόσουμε κάποια τεχνική διαγραφής γραμμών ή συμπλήρωσης (imputation) ελλιπουσών τιμών.

1.4 Έλεγχος για διπλότυπες εγγραφές και ακραίες τιμές

Ελέγξαμε το dataset και διαπιστώσαμε ότι δεν υπάρχουν καθόλου διπλότυπες εγγραφές.
Για τον εντοπισμό ακραίων τιμών βασιστήκαμε σε θηκογράμματα (boxplots).



Σχήμα 1: Box plot για age, wtkg, karnof, cd40, cd80, cd420

Από το Σχήμα 1 παρατηρούμε την ύπαρξη τιμών που αποκλίνουν σημαντικά. Ωστόσο, επειδή τα δεδομένα προέρχονται από κλινικές μετρήσεις, αυτές οι ”ακραίες” τιμές αντιπροσωπεύουν πραγματική, φυσιολογική διακύμανση στον πληθυσμό των ασθενών και όχι σφάλματα εισαγωγής δεδομένων. Ακόμη, θεωρούμε ότι σε τέτοιες έρευνες οι ακραίες τιμές είναι σημαντικές για την επίλυση των προβλημάτων, καθώς μας παρέχουν σημαντική πληροφορία. Για τον λόγο αυτό, αποφασίσαμε να μην τις αφαιρέσουμε, διατηρώντας ακέραιη την ιατρική πληροφορία.

1.5 Βασικά περιγραφικά στατιστικά

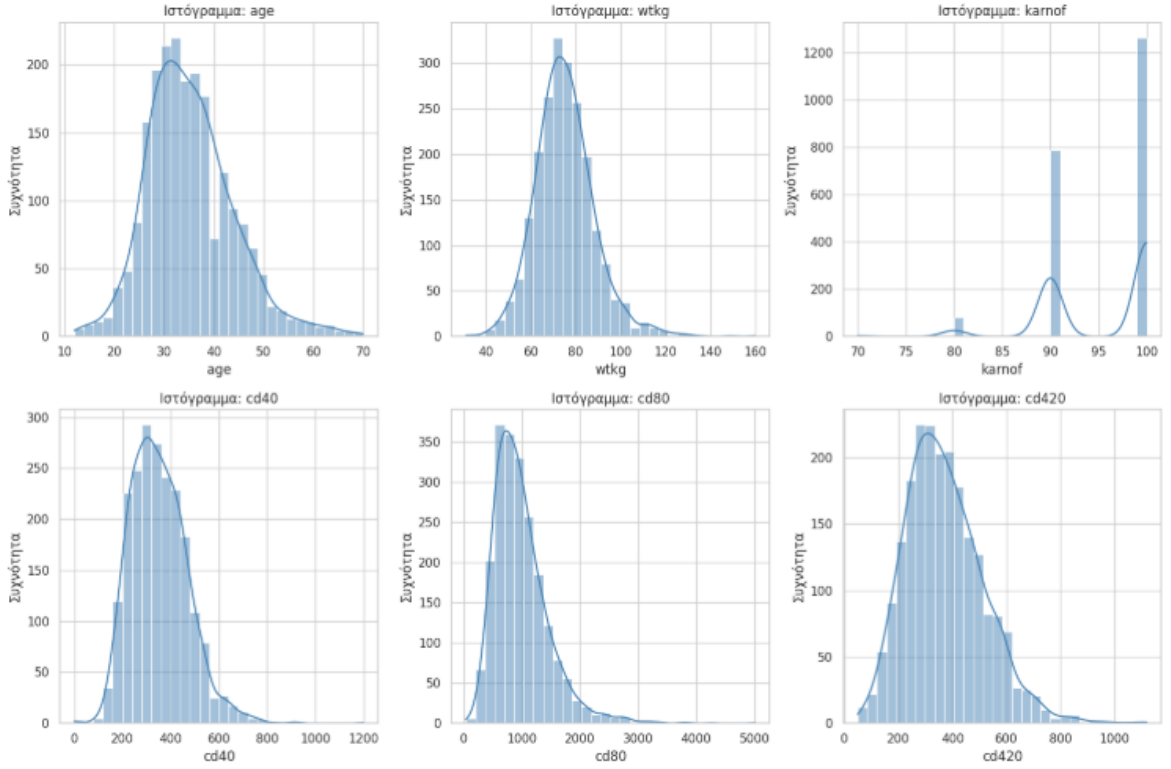
index	count	mean	std	min	25%	50%	75%	max
trt	2139.0	1.52	1.13	0.0	1.0	2.0	3.0	3.0
age	2139.0	35.25	8.71	12.0	29.0	34.0	40.0	70.0
wtkg	2139.0	75.13	13.26	31.0	66.68	74.39	82.56	159.94
hemo	2139.0	0.08	0.28	0.0	0.0	0.0	0.0	1.0
homo	2139.0	0.66	0.47	0.0	0.0	1.0	1.0	1.0
drugs	2139.0	0.13	0.34	0.0	0.0	0.0	0.0	1.0
karnof	2139.0	95.45	5.9	70.0	90.0	100.0	100.0	100.0
oprior	2139.0	0.02	0.15	0.0	0.0	0.0	0.0	1.0
z30	2139.0	0.55	0.5	0.0	0.0	1.0	1.0	1.0
zprior	2139.0	1.0	0.0	1.0	1.0	1.0	1.0	1.0
preanti	2139.0	379.18	468.66	0.0	0.0	142.0	739.5	2851.0
race	2139.0	0.29	0.45	0.0	0.0	0.0	1.0	1.0
gender	2139.0	0.83	0.38	0.0	1.0	1.0	1.0	1.0
str2	2139.0	0.59	0.49	0.0	0.0	1.0	1.0	1.0
strat	2139.0	1.98	0.9	1.0	1.0	2.0	3.0	3.0
symptom	2139.0	0.17	0.38	0.0	0.0	0.0	0.0	1.0
treat	2139.0	0.75	0.43	0.0	1.0	1.0	1.0	1.0
cd40	2139.0	350.5	118.57	0.0	263.5	340.0	423.0	1199.0
cd420	2139.0	371.31	144.63	49.0	269.0	353.0	460.0	1119.0
cd80	2139.0	986.63	480.2	40.0	654.0	893.0	1207.0	5011.0

Σχήμα 2: Περιγραφικά στατιστικά

Στο Σχήμα 2 έχουμε αφεραίσει τις μεταβλητές οι οποίες μπορεί να προκαλλέσουν data leakage. Το πλήθος των παρατηρήσεων είναι σε 2139 για κάθε μεταβλητή, γεγονός που επαληθεύει την πλήρη απουσία ελλιπών τιμών. Η μέση ηλικία (age) των ασθενών είναι τα 35,25 έτη, με το ηλικιακό εύρος να κυμαίνεται από 12 έως 70 έτη. Επιπλέον, παρατηρούμε σημαντική διακύμανση στις αρχικές κλινικές μετρήσεις: για παράδειγμα, η αρχική τιμή των κυττάρων CD4 (cd40) έχει μέση τιμή 350,5 και σχετικά μεγάλη τυπική απόκλιση (118,57), ενώ η μεταβλητή-στόχος (cd420) έχει μέση τιμή 371,31. Οι έντονες διαφορές στις κλίμακες των τιμών (π.χ. δείκτες όπως το hemo παίρνουν τιμές 0 ή 1, ενώ η μεταβλητή cd80 έχει μέγιστη τιμή 5011) καθιστούν επιβεβλημένη την τυποποίηση (standardization) των συνεχών μεταβλητών στο επόμενο στάδιο της προεπεξεργασίας. Επίσης, η μεταβλητή zprior που συμβολίζει αν ο ασθενής είχε πάρει ποτέ στο παρελθόν Ζιδοβουδίνη παρατηρούμε ότι έχει τυπική απόκλιση (std) ακριβώς 0.0. Αυτό σημαίνει ότι όλοι ανεξαιρέτως οι 2139 ασθενείς του dataset έχουν ακριβώς την ίδια τιμή σε αυτή τη μεταβλητή, έχει δηλαδή μηδενική διακύμανση. Στη μηχανική μάθηση, ένα χαρακτηριστικό που έχει ακριβώς την ίδια τιμή για όλες τις παρατηρήσεις δεν προσφέρει καμία απολύτως πληροφορία στο μοντέλο, καθώς δεν μπορεί να εξηγήσει καμία διαφοροποίηση στη μεταβλητή-στόχο. Άρα θα την αφαιρέσουμε από τη μελέτη μας.

1.6 Οπτικοποιήσεις δεδομένων

Για την καλύτερη κατανόηση της κατανομής των δεδομένων και των σχέσεων μεταξύ των μεταβλητών, προχωρήσαμε στη δημιουργία των κατάλληλων οπτικοποιήσεων.



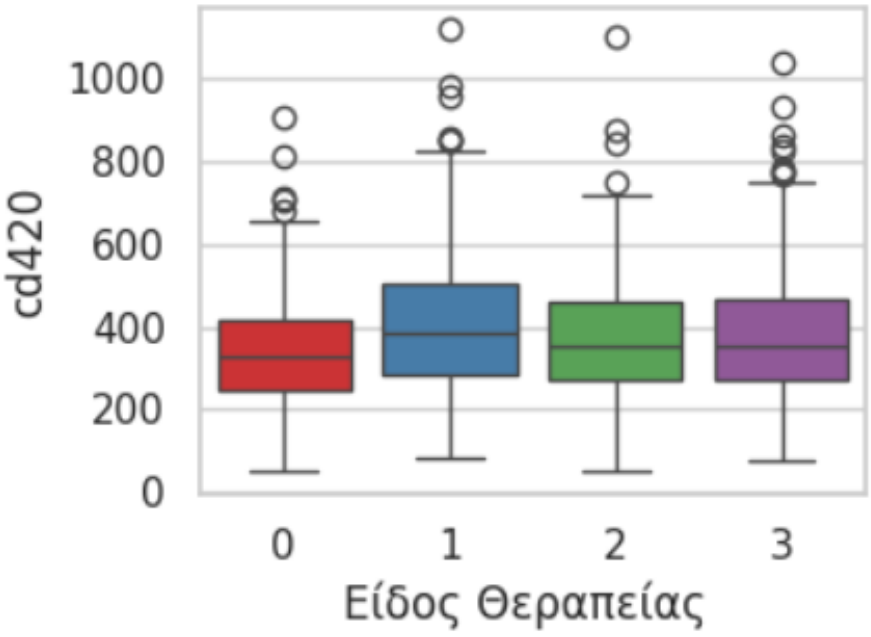
Σχήμα 3: Ιστόγραμμα, ηλικίας, κιλών, karnof score, cd40,cd80 cd420

Στο Σχήμα 3 αποτυπώνονται τα ιστογράμματα των συνεχών μεταβλητών του συνόλου δεδομένων, τα οποία μας επιτρέπουν να μελετήσουμε τη μορφή των κατανομών τους.

Ηλικία (age) και Βάρος (wtkg): Οι δύο αυτές μεταβλητές ακολουθούν μια κατανομή που προσεγγίζει σε μεγάλο βαθμό την κανονική. Η πλειοψηφία των ασθενών συγκεντρώνεται γύρω από τη μέση τιμή (περίπου τα 35 έτη για την ηλικία και τα 75 κιλά για το βάρος). Στο ιστόγραμμα του βάρους παρατηρούμε και μια ελαφριά «ουρά» προς τα δεξιά, η οποία οφείλεται σε ορισμένες μεμονωμένες περιπτώσεις ασθενών με μεγαλύτερο σωματικό βάρος.

Karnofsky score: Η κατανομή παρουσιάζει έντονη αριστερή ασυμμετρία. Η συντριπτική πλειοψηφία των παρατηρήσεων συγκεντρώνεται αποκλειστικά στις τιμές 90 και 100, με ελάχιστες καταγραφές στο 80. Αυτό σημαίνει πρακτικά ότι κατά την έναρξη της μελέτης, σχεδόν όλοι οι ασθενείς βρίσκονταν σε πολύ καλή έως άριστη λειτουργική κατάσταση, ικανοί να φέρουν εις πέρας φυσιολογικές δραστηριότητες.

Μετρήσεις Κυττάρων (cd40, cd80, cd420): Τόσο οι αρχικές μετρήσεις των Τ-λεμφοκυττάρων (στο χρόνο 0), όσο και η μεταβλητή-στόχος (στις 20 εβδομάδες) παρουσιάζουν σαφή δεξιά ασυμμετρία. Παρατηρούμε ότι ο μεγαλύτερος όγκος των δεδομένων συσσωρεύεται σε χαμηλές έως μεσαίες τιμές (για παράδειγμα, γύρω στο 300-400 για τα CD4 και στο 800-1000 για τα CD8). Η μακριά αυτή «ουρά» υποδεικνύει την ύπαρξη λίγων ασθενών με εξαιρετικά υψηλούς αριθμούς κυττάρων.



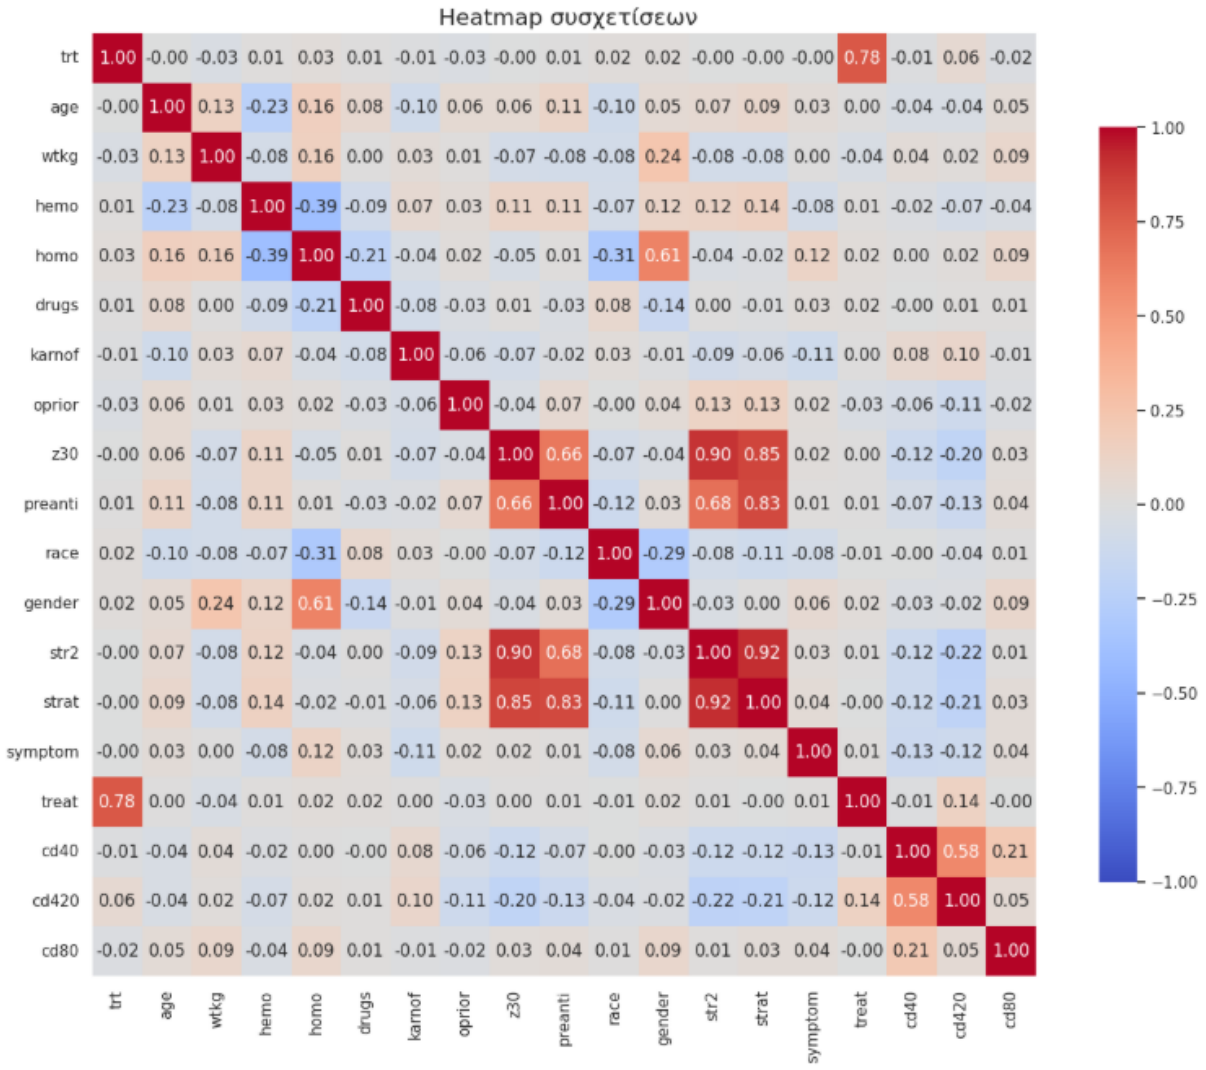
Σχήμα 4: Box plot είδος θεραπείας vs cd420

Στο Σχήμα 4 απεικονίζεται η κατανομή της μεταβλητής-στόχου (cd420 - αριθμός κυττάρων CD4 στις 20 εβδομάδες) σε σχέση με τις τέσσερις διαφορετικές κατηγορίες θεραπευτικής αγωγής (Είδος Θεραπείας: 0, 1, 2, 3). Θεραπεία 0: Φαίνεται να σχετίζεται με τον χαμηλότερο διάμεσο αριθμό κυττάρων CD4 στις 20 εβδομάδες (κοντά στο 300) σε σύγκριση με τις υπόλοιπες αγωγές.

Θεραπεία 1 : Παρουσιάζει την υψηλότερη διάμεσο τιμή (κοντά στο 400) και το υψηλότερο άνω τεταρτημόριο υποδεικνύοντας ότι, κατά μέσο όρο, οι ασθενείς σε αυτή την ομάδα εμφάνισαν την καλύτερη ανοσολογική απόκριση ως προς τα κύτταρα CD4.

Θεραπείες 2 και 3: Εμφανίζουν πολύ παρόμοια συμπεριφορά μεταξύ τους. Οι διάμεσοι τους κυμαίνονται σε ενδιάμεσα επίπεδα, ελαφρώς υψηλότερα από τη θεραπεία 0 αλλά ξεκάθαρα χαμηλότερα από την 1.

Ακραίες Τιμές (Outliers): Σε όλες ανεξαιρέτως τις ομάδες θεραπείας εντοπίζονται αρκετές ακραίες τιμές προς τα πάνω. Αυτό μας δείχνει ότι, ανεξαρτήτως της βασικής τάσης της εκάστοτε αγωγής, σε κάθε ομάδα υπήρξαν μεμονωμένοι ασθενείς που σημείωσαν εξαιρετικά υψηλές μετρήσεις CD4 (ακόμα και πάνω από 1000).

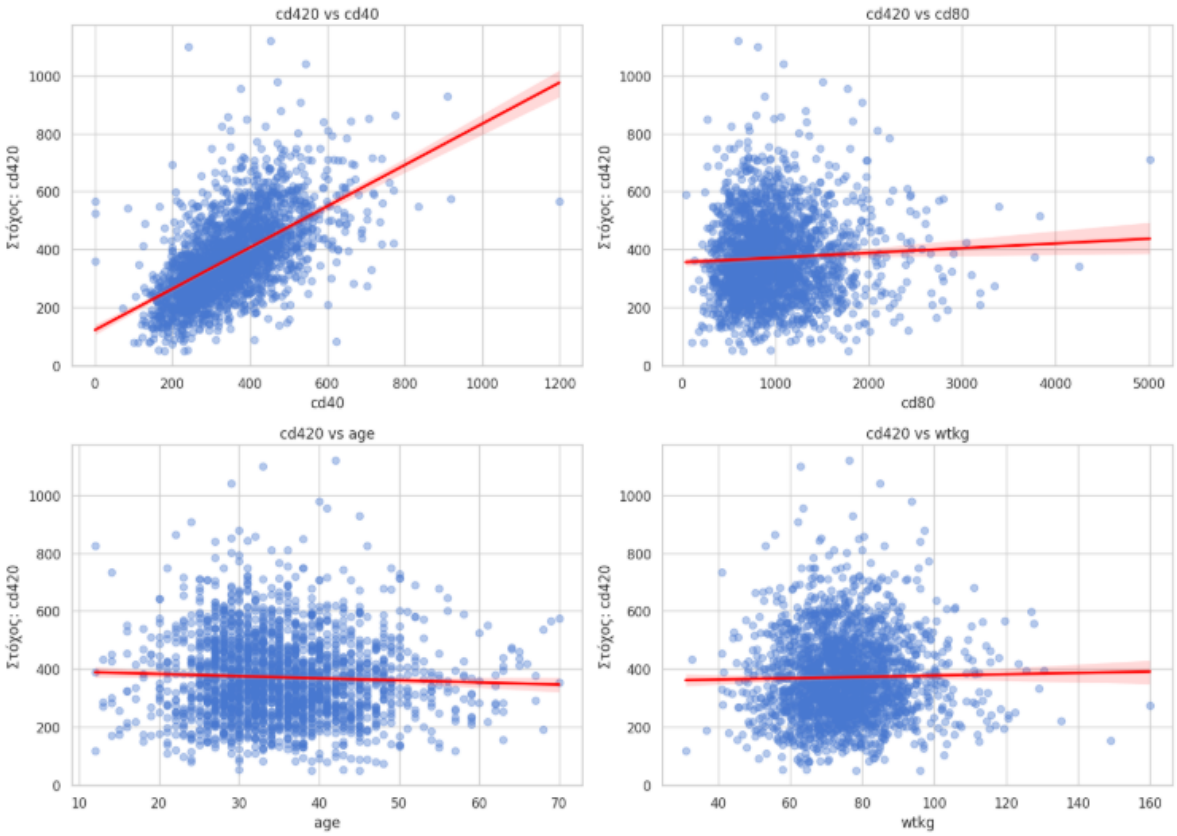


Σχήμα 5: Heatmap συσχετίσεων

Στο Σχήμα 5 αποτυπώνουμε τους συντελεστές γραμμικής συσχέτισης Pearson μεταξύ όλων των αριθμητικών μεταβλητών του συνόλου δεδομένων. Η μελέτη του διαγράμματος μας οδηγεί σε δύο βασικούς άξονες συμπερασμάτων:

Συσχετίσεις με τη μεταβλητή-στόχο (cd420): Επιβεβαιώνουμε και ποσοτικά ότι η ισχυρότερη θετική συσχέτιση εντοπίζεται με την αρχική μέτρηση των T-λεμφοκυττάρων cd40 ($r = 0.58$). Οι υπόλοιπες μεταβλητές παρουσιάζουν από πολύ αδύναμες έως μηδαμινές γραμμικές συσχετίσεις. Για παράδειγμα, μεταβλητές που αφορούν προηγούμενο ιστορικό θεραπειών (όπως str2, strat, z30) εμφανίζουν ασθενή αρνητική συσχέτιση (κοντά στο -0.20).Ακόμη, χαρακτηριστικά όπως η ηλικία και το βάρος (age, wtkg, gender, race) έχουν συντελεστές συσχέτισης σχεδόν μηδενικούς, υποδηλώνοντας την απουσία γραμμικής εξάρτησης με τον μελλοντικό αριθμό κυττάρων CD4.2.

Παρατηρούμε ένα «μπλοκ» μεταβλητών με πολύ υψηλούς θετικούς συντελεστές. Συγκεκριμένα, οι μεταβλητές str2, strat, και z30 είναι έντονα συσχετισμένες μεταξύ τους (π.χ. str2 και strat έχουν $r = 0.92$, str2 και z30 έχουν $r = 0.90$). Επίσης, η μεταβλητή preanti συσχετίζεται σημαντικά με αυτές. Οι μεταβλητές trt και treat εμφανίζουν ισχυρή συσχέτιση ($r = 0.78$), καθώς και οι δύο αφορούν πληροφορία σχετική με το είδος της αγωγής. Αυτή η πολυσυγγραμμικότητα σημαίνει ότι κάποιες μεταβλητές μεταφέρουν επικαλυπτόμενη (περιττή) πληροφορία, γεγονός που ίσως χρειαστεί να διαχειριστούμε στο στάδιο της επιλογής χαρακτηριστικών (feature selection) για να βελτιώσουμε την ερμηνευσιμότητα και τη σταθερότητα των μοντέλων μας.



Σχήμα 6: Scatter plots, cd40,cd80, ηλικία, βάρος

Στα Σχήμα 6 μελετήσαμε οπτικά τη σχέση της μεταβλητής-στόχου cd420 με τέσσερα επιλεγμένα χαρακτηριστικά. Η προσθήκη της γραμμής τάσης (κόκκινη γραμμή παλινδρόμησης) επιβεβαιώνει πλήρως τα ευρήματα του heatmap:

Στο γράφημα cd420 - cd40 , παρατηρούμε μια ισχυρή ανοδική τάση. Τα δεδομένα ακολουθούν τη θετική γραμμή παλινδρόμησης, επιβεβαιώνοντας με απόλυτη σαφήνεια ότι οι ασθενείς με υψηλότερα επίπεδα κυττάρων CD4 στην αρχή της θεραπείας, τείνουν να έχουν υψηλότερα επίπεδα και στις 20 εβδομάδες.

Στα υπόλοιπα τρία διαγράμματα (cd80, age, wtkg), η κόκκινη γραμμή τάσης είναι σχεδόν εντελώς οριζόντια. Τα δεδομένα είναι διάσπαρτα γύρω από τη γραμμή, χωρίς καμία εμφανή κατεύθυνση. Αυτό αποδεικνύει οπτικά ότι χαρακτηριστικά όπως η ηλικία, το βάρος και τα αρχικά CD8 δεν προσφέρουν ισχυρή γραμμική πληροφορία για την πρόβλεψη του πλήθους των cd4 κυττάρων μετά από 20 (± 5) εβδομάδες.

1.7 Σχολιασμός συσχέτισης χαρακτηριστικών με τη μεταβλητή-στόχο

Βάσει της αρχικής διερεύνησης των δεδομένων και των οπτικοποιήσεων (heatmap συσχετίσεων και διαγράμματα διασποράς), προκύπτουν τα εξής συμπεράσματα σχετικά με τα χαρακτηριστικά που ξεχωρίζουν εκ πρώτης όψεως:

Το χαρακτηριστικό που σχετίζεται περισσότερο με τη μεταβλητή-στόχο (cd420) είναι με διαφορά η αρχική μέτρηση των T-λεμφοκυττάρων, δηλαδή η μεταβλητή cd40. Η συσχέτιση αυτή είναι σαφώς θετική και γραμμική (Pearson r = 0.58). Αυτό είναι απολύτως αναμενόμενο και κλινικά, καθώς η αρχική κατάσταση του ανοσοποιητικού συστήματος ενός ασθενούς αποτελεί τον κύριο προγνωστικό παράγοντα για τη μελλοντική του πορεία. Σε δεύτερη μοίρα, παρατηρούμε μια θετική αλλά αισθητά πιο αδύναμη συσχέτιση με την αρχική μέτρηση των κυττάρων cd80. Αντίθετα, χαρακτηριστικά όπως η ηλικία (age) και το σωματικό βάρος (wtkg) δεν παρουσιάζουν καμία απολύτως γραμμική εξάρτηση με τη μεταβλητή-στόχο. Οι συντελεστές συσχέτισής τους προσεγγίζουν το μηδέν, γεγονός που επιβεβαιώνεται οπτικά και από την τυχαία κατανομή των σημείων στα αντίστοιχα διαγράμματα διασποράς.

2 Προεπεξεργασία δεδομένων

2.1 Διαχωρισμός Δεδομένων (Train/Test Split)

Για την αξιολόγηση της γενικευτικής ικανότητας των μοντέλων που πρόκειται να αναπτύξουμε, προχωρήσαμε στον διαχωρισμό του συνόλου δεδομένων σε δεδομένα εκπαίδευσης (training set) και δεδομένα ελέγχου (test set). Επιλέξαμε την τυπική αναλογία 80/20, που σημαίνει ότι το 80% των παρατηρήσεων χρησιμοποιείται αποκλειστικά για την εκπαίδευση των αλγορίθμων, ενώ το υπόλοιπο 20% διατηρείται αυστηρά «κρυφό» για την τελική αξιολόγηση της απόδοσής τους. Προκειμένου να διασφαλίσουμε την απόλυτη αναπαραγωγιμότητα των πειραμάτων μας σε κάθε εκτέλεση του κώδικα, ορίσαμε μια σταθερή τιμή στην παράμετρο random_state(=30).

2.2 Κανονικοποίηση ή τυποποίηση

Όπως διαπιστώσαμε από τα περιγραφικά στατιστικά στην προηγούμενη ενότητα, τα χαρακτηριστικά του dataset έχουν πολύ διαφορετικές κλίμακες και μονάδες μέτρησης (π.χ. η ηλικία μετριέται σε δεκάδες, ενώ οι μετρήσεις των κυττάρων CD4 και CD8 σε εκατοντάδες). Η κλιμάκωση (scaling) των δεδομένων κρίνεται απολύτως απαραίτητη. Οι αλγόριθμοι που θα χρησιμοποιήσουμε στην επόμενη ενότητα είτε βασίζονται στον υπολογισμό αποστάσεων, είτε χρησιμοποιούν gradient descent. Χωρίς κλιμάκωση, τα χαρακτηριστικά με το μεγαλύτερο εύρος τιμών θα κυριαρχούσαν στους υπολογισμούς, προκαλώντας αστάθεια και υποβαθμίζοντας την απόδοση των μοντέλων.

Μεταξύ των διαθέσιμων τεχνικών, επιλέξαμε να εφαρμόσουμε τυποποίηση (standardization) στις συνεχείς μεταβλητές του συνόλου δεδομένων. Η μέθοδος αυτή (StandardScaler) μετασχηματίζει τα δεδομένα ώστε η κάθε μεταβλητή να έχει μέση τιμή 0 και τυπική απόκλιση 1. Προτιμήσαμε την τυποποίηση έναντι της κανονικοποίησης , διότι η τυποποίηση δεν «συμπιέζει» αυστηρά τα δεδομένα σε ένα προκαθορισμένο διάστημα [0, 1]. Αυτό την καθιστά ελαφρώς πιο ανθεκτική (robust) στη διαχείριση των outliers.
Εφαρμόζουμε το StandardScaler αποκλειστικά στις μεταβλητές που εκφράζουν μέγεθος ή ποσότητα (age, wtkg, cd40, cd80, preanti, karnof), διότι εκεί έχει νόημα να βρούμε τον μέσο όρο και την τυπική απόκλιση.

2.3 Κωδικοποίηση κατηγορικών μεταβλητών (necoding)

Αν και στο σύνολο δεδομένων (ACTG 175) οι κατηγορικές μεταβλητές είναι ήδη εκφρασμένες με ακέραιους αριθμούς (π.χ. το φύλο ως 0 ή 1, το είδος θεραπείας trt ως 0, 1, 2, 3), οφείλουμε να τις διαχειριστούμε προσεκτικά για να μην παραπλανήσουμε τα μοντέλα μας. Συγκεκριμένα, για μεταβλητές που παίρνουν αποκλειστικά δύο τιμές (gender, hemo, drugs, symptom, κ.λπ.), η υπάρχουσα κωδικοποίηση 0 και 1 είναι ιδανική. Οι αλγόριθμοι μπορούν να τις διαβάσουν απευθείας ως λογικές ”σημαίες” (flags) απουσίας ή παρουσίας ενός χαρακτηριστικού, οπότε δεν απαιτείται καμία περαιτέρω μετατροπή. Το πρόβλημα βρίσκεται στη μεταβλητή του είδους θεραπείας (trt), η οποία διαθέτει τέσσερις ξεχωριστές κλάσεις (0, 1, 2, 3), αυτοί οι αριθμοί αποτελούν απλές ταμπέλες και δεν κρύβουν κάποια ιεράρχιση. Αν αφήναμε τη μεταβλητή ως έχει, οι αλγόριθμοι θα υπέθεταν λανθασμένα ότι υπάρχει μια τέτοια αριθμητική εξάρτηση. Για την επίλυση αυτού του προβλήματος, θα εφαρμόσουμε One-Hot Encoding στη μεταβλητή trt. Η τεχνική αυτή δημιουργεί νέες, ξεχωριστές δυαδικές στήλες (dummy variables) για κάθε κατηγορία της θεραπείας. Επιπλέον, θα χρησιμοποιήσουμε την παράμετρο drop=’first’, αφαιρώντας την πρώτη δυαδική στήλη που προκύπτει. Αυτό είναι ένα κρίσιμο βήμα για να αποφύγουμε την παγίδα των ψευδομεταβλητών, η μία στήλη είναι γραμμικά εξαρτημένη από τις υπόλοιπες, εξασφαλίζοντας έτσι τη σταθερότητα των γραμμικών αλγορίθμων που θα εκπαιδεύσουμε στη συνέχεια.

2.4 Τεκμηρίωση αποφυγής διαρροής δεδομένων

Η διαρροή δεδομένων (data leakage) συμβαίνει όταν πληροφορίες από το σύνολο ελέγχου (test set) χρησιμοποιούνται, άμεσα ή έμμεσα, κατά τη διαδικασία εκπαίδευσης του μοντέλου. Αυτό οδηγεί σε υπεραισιόδοξα αποτελέσματα απόδοσης, τα οποία όμως δεν αντικατοπτρίζουν την πραγματική ικανότητα του μοντέλου να γενικεύει σε νέα, άγνωστα για αυτό δεδομένα, δηλαδή πλήρη αποτυχία όταν το μοντέλο κληθεί να προβλέψει τον αριθμό κυττάρων CD4 σε έναν νέο ασθενή εκτός του δείγματος.

Κατά την τυποποίηση (Standardization), υπολογίζουμε τη μέση τιμή (μ) και την τυπική απόκλιση (σ). Αν αυτοί οι δείκτες υπολογιστούν σε ολόκληρο το dataset, οι τιμές του training set θα έχουν "μολυνθεί" από την κατανομή του test set. Το μοντέλο θα εκπαιδευτεί σε δεδομένα που έχουν προσαρμοστεί λαμβάνοντας υπόψη το μέλλον (το test set), κάτι που είναι αδύνατο σε πραγματικές συνθήκες πρόβλεψης. Το test set πρέπει να προσομοιώνει δεδομένα που το μοντέλο θα συναντήσει για πρώτη φορά. Αν χρησιμοποιήσουμε το test set για να ορίσουμε τα όρια του One-Hot Encoding ή τις παραμέτρους του Scaler, παραβιάζουμε αυτή την απομόνωση.

Για να διασφαλίσουμε την ακεραιότητα της διαδικασίας, η εκμάθηση των παραμέτρων (μέση τιμή, κατηγορίες encoding) γίνεται μόνο στο X_train (training set). Η εφαρμογή των μετασχηματισμών γίνεται τόσο στο X_train όσο και στο X_test, χρησιμοποιώντας όμως αποκλειστικά τις παραμέτρους που προέκυψαν από το X_train.

3 Δημιουργία baseline μοντέλων

Για την πρόβλεψη του αριθμού των κυττάρων CD4 (cd420), επιλέξαμε να υλοποιήσουμε και να συγκρίνουμε πέντε διαφορετικούς αλγορίθμους:

Linear Regression: Είναι ο πιο απλός και ερμηνεύσιμος αλγόριθμος. Θα μας δείξει αν η σχέση μεταξύ των χαρακτηριστικών και του στόχου είναι γραμμική.

Random Forest Regressor: Ένας ensemble αλγόριθμος που βασίζεται στην τεχνική του Bagging (συνδυάζει πολλά δέντρα απόφασης). Είναι εξαιρετικά ανθεκτικός σε outliers και μη-γραμμικές σχέσεις, ενώ σπάνια κάνει υπερπροσαρμογή.

Gradient Boosting Regressor: Ακόμα ένας ensemble αλγόριθμος αλλά βασισμένος στο Boosting (κάθε νέο δέντρο διορθώνει τα λάθη του προηγούμενου). Θεωρείται ο ιδανικός για tabular δεδομένα και συχνά πετυχαίνει πολύ υψηλή ακρίβεια.

Support Vector Regression (SVR): Μια εντελώς διαφορετική προσέγγιση, προσπαθεί να βρει ένα μονοπάτι που να περιέχει τα περισσότερα σημεία. Είναι ένα μοντέλο το οποίο μας επιτρέπει να εκμεταλλευτούμε την τυποποίηση (Standardization) που κάναμε στην προηγούμενη ενότητα.

K-Nearest Neighbors Regressor (KNN): Βασίζεται αποκλειστικά στον υπολογισμό αποστάσεων (ευκλείδεια απόσταση) μεταξύ των ασθενών.

3.1-3.3 Εκπαιδεύση των μοντέλων με default ρυθμίσεις, υπολογισμός μετρικών και παρουσίαση πίνακα αποτελεσμάτων

Πίνακας 1: Αξιολόγηση Baseline μοντέλων παλινδρόμησης στο test set

Μοντέλο (Αλγόριθμος)	**MAE**	**MSE**	**RMSE**	R^2
Linear Regression	83.20	12110.65	110.05	0.431
Gradient Boosting	85.83	12722.97	112.80	0.403
Random Forest	87.24	13175.82	114.79	0.381
KNN	98.09	16531.27	128.57	0.224
SVR	100.67	17140.07	130.92	0.195

Στον Πίνακα 1 έχουμε κάνει στρογγυλοποίηση στα δεκαδικά ψηφία. Ακόμη έχουμε παραθέσει τα αποτελέσματα αξιολόγησης των πέντε μοντέλων παλινδρόμησης (baseline), όπως αυτά εφαρμόστηκαν στο σύνολο ελέγχου (test set). Από τη συγκριτική μελέτη των μετρικών σφάλματος (MAE, MSE, RMSE) και του συντελεστή προσδιορισμού (R^2), εξάγουμε τα ακόλουθα συμπεράσματα για τη συμπεριφορά των αλγορίθμων.

3.4 Απόδοση μοντέλων

Αρχικά, παρατηρούμε ότι η γραμμική παλινδρόμηση (Linear Regression) αποτελεί το μοντέλο με την υψηλότερη προβλεπτική ικανότητα, επιτυγχάνοντας το χαμηλότερο Μέσο Απόλυτο Σφάλμα (MAE = 83.20) και ερμηνεύοντας το μεγαλύτερο ποσοστό της διακύμανσης της μεταβλητής-στόχου ($R^2 = 0.431$). Άρα, μπορούμε να θεωρήσουμε ότι η σχέση μεταξύ των ανεξάρτητων μεταβλητών και του στόχου στο συγκεκριμένο σύνολο δεδομένων είναι σε μεγάλο βαθμό γραμμική. Στη δεύτερη και τρίτη θέση της κατάταξης ακολουθούν τα μοντέλα που βασίζονται σε δέντρα απόφασης. Συγκεκριμένα, ο αλγόριθμος Gradient Boosting παρουσιάζει εξαιρετική συμπεριφορά (MAE = 85.83, $R^2 = 0.403$), ακολουθούμενος από το Random Forest (MAE = 87.24, $R^2 = 0.381$). Αν και τα μοντέλα αυτά φημίζονται για την ικανότητά τους να μοντελοποιούν πολύπλοκες, μη-γραμμικές σχέσεις, στην παρούσα φάση υστερούν οριακά έναντι του απλού γραμμικού μοντέλου. Αυτό πιθανότατα οφείλεται στο γεγονός ότι εκπαιδεύτηκαν με τις προεπιλεγμένες (default) υπερπαραμέτρους τους, γεγονός που ίσως τα οδήγησε σε ελαφριά υπερπροσαρμογή (overfitting) στον θόρυβο των δεδομένων εκπαίδευσης. Αντιθέτως, η απόδοση των αλγορίθμων k-Nearest Neighbors (KNN) και Support Vector Regression (SVR) είναι χαμηλή, ακόμη καταγράφουν τα υψηλότερα σφάλματα και τους χαμηλότερους συντελεστές R^2 (0.224 και 0.195, αντίστοιχα). Και οι δύο αυτοί αλγόριθμοι είναι εξαιρετικά ευαίσθητοι τόσο στην κλιμάκωση των δεδομένων (την οποία έχουμε ήδη αντιμετωπίσει μέσω τυποποίησης) όσο και στον καθορισμό των υπερπαραμέτρων τους. Η χρήση των default τιμών (π.χ. αυθαίρετος αριθμός γειτόνων στο KNN ή μη βελτιστοποιημένο περιθώριο ανοχής στο SVR) δεν τους επιτρέπει να αναδείξουν τη δυναμική τους. Συνοψίζοντας, η αξιολόγηση των baseline μοντέλων μάς δείχνει ότι η απλή γραμμική προσέγγιση θέτει ένα ισχυρό σημείο αναφοράς.

4 Διασταυρούμενη επικύρωση

4.1 Εφαρμογή k-Fold Cross-Validation

Για την εφαρμογή της διασταυρούμενης επικύρωσης (cross-validation), επιλέξαμε τη στρατηγική k-fold με k=5. Χωρίσαμε το σύνολο εκπαίδευσης σε 5 ισομεγέθη, αλληλοαποκλειόμενα υποσύνολα. Κάθε αλγόριθμος εκπαιδεύτηκε 5 ξεχωριστές φορές, χρησιμοποιώντας τα 4 υποσύνολα για την εκπαίδευσή του και το 5ο για την επικύρωση. Επιπλέον, ενεργοποιήσαμε την παράμετρο ανακατέματος (shuffle=True) για να εξασφαλίσουμε την τυχαία κατανομή των παρατηρήσεων στα υποσύνολά μας. Για να αποφύγουμε τυχόν data leakage κατά τη διάρκεια του cross-validation, χρησιμοποιήσαμε pipeline. Ο λόγος που το κάναμε αυτό ήταν γιατί εάν η προεπεξεργασία εφαρμοζόταν σε ολόκληρο το training set πριν από το split του k-fold, οι στατιστικές παράμετροι του μετασχηματισμού θα είχαν «μολυνθεί» από τα δεδομένα των πτυχών επικύρωσης. Το Pipeline εγγυάται ότι σε κάθε επανάληψη (fold), ο μετασχηματισμός των δεδομένων (fit και transform) μαθαίνεται αποκλειστικά από τα δεδομένα εκπαίδευσης της εκάστοτε πτυχής και στη συνέχεια εφαρμόζεται στα δεδομένα ελέγχου.

4.2 Σύγκριση των επιδόσεων των μοντέλων με βάση τη μέση τιμή και την τυπική απόκλιση των μετρικών.

Πίνακας 2: Αποτελέσματα 5-Fold Cross-Validation με χρήση Pipeline

Μοντέλο (Αλγόριθμος)	**Mean R^2**	**Std R^2**	**Mean MAE**	**Std MAE**
Linear Regression	0.378	0.061	84.71	2.91
Gradient Boosting	0.376	0.046	85.25	3.40
Random Forest	0.347	0.059	87.71	2.72
KNN	0.215	0.054	98.05	2.68
SVR	0.173	0.014	100.06	2.64

Από τον Πίνακα 2 μπορούμε να εξάγουμε τα ακόλουθα συμπεράσματα:
Η Γραμμική Παλινδρόμηση επιτυγχάνει την καλύτερη μέση επίδοση με το χαμηλότερο μέσο απόλυτο σφάλμα (Mean MAE = 84.71) και το υψηλότερο ποσοστό επεξήγησης της διακύμανσης (Mean R^2 = 0.378). Ωστόσο, η διαφορά με το Gradient Boosting είναι αρκετά μικρή (Mean R^2 = 0.376, Mean MAE = 85.25). Το Gradient Boosting παρουσιάζει μικρότερη διακύμανση στον συντελεστή R^2 (Std R^2 = 0.046) έναντι (0.061) της Γραμμικής. Αυτό υποδηλώνει ότι, παρότι η Γραμμική Παλινδρόμηση είναι οριακά πιο ακριβής κατά μέσο όρο, το Gradient Boosting εμφανίζεται ελαφρώς πιο σταθερό ως προς την ερμηνευτική του ικανότητα ανεξαρτήτως του πώς θα χωριστούν τα δεδομένα. Το Random Forest βρίσκεται στην τρίτη θέση (Mean R^2 = 0.347, Mean MAE = 87.71) και παρότι υπολείπεται σε ακρίβεια από τα δύο μοντέλα που σχολιάσαμε προηγουμένως, διατηρεί ένα χαμηλό και σταθερό σφάλμα (Std MAE = 2.72). Αυτό επιβεβαιώνει τη θεωρητική του ιδιότητα ως ensemble αλγόριθμου που μέσω της τεχνικής του bagging καταφέρνει να περιορίζει τη διακύμανση των επιμέρους δέντρων απόφασης. Ο αλγόριθμος KNN καταγράφει χαμηλή μέση επίδοση (Mean R^2 = 0.215), η αδυναμία του αυτή αποδεικνύει ότι η απλή χρήση της Ευκλείδειας απόστασης, χωρίς βελτιστοποίηση του αριθμού των γειτόνων δεν αρκεί για να μοντελοποιήσει αξιόπιστα τη συγκεκριμένη μεταβλητή-στόχο. Τέλος, το Support Vector Regression (SVR) έχει τη χειρότερη επίδοση, με το υψηλότερο σφάλμα (Mean MAE = 100.06) και το χαμηλότερο Mean R^2 (0.173). Ακόμη, έχει τη μικρότερη τυπική απόκλιση από όλα τα μοντέλα (Std R^2 = 0.014, Std MAE = 2.64). Η εξαιρετικά χαμηλή διακύμανση σε συνδυασμό με τη χαμηλή ακρίβεια αποτελεί κλασική ένδειξη υψηλής μεροληψίας (high bias). Αυτό επιβεβαιώνει ότι οι default υπερπαράμετροι του SVR αδυνατούν να συλλάβουν την πολυπλοκότητα των συγκεκριμένων δεδομένων.

4.3 Αξιοπιστία της Cross-Validation έναντι ενός μόνο split

Η μέθοδος K-Fold Cross-Validation παρέχει μια κριτικά πιο αξιόπιστη και ρεαλιστική εκτίμηση της γενικευτικής ικανότητας ενός μοντέλου σε σύγκριση με έναν απλό διαχωρισμό (single train/test split).
Σε ένα απλό train/test split, η εκτίμηση της απόδοσης εξαρτάται απόλυτα από το random state του διαχωρισμού, υπάρχει πάντα ο κίνδυνος το test set να περιέχει μη αντιπροσωπευτικά δείγματα (π.χ. ασθενείς με ασυνήθιστα εύκολη ή δύσκολη κλινική εικόνα), οδηγώντας σε αισιόδοξη ή απαισιόδοξη μεροληψία αντίστοιχα. Το K-Fold εξομαλύνει αυτή την τυχαιότητα, καθώς η τελική εκτίμηση προκύπτει από τον μέσο όρο k διαφορετικών, ανεξάρτητων πειραμάτων, μειώνοντας δραστικά τη διακύμανση της εκτίμησης του σφάλματος.
Σε ένα κλασικό split (π.χ. 80/20), το 20% των δεδομένων δεσμεύεται αποκλειστικά για αξιολόγηση και το μοντέλο στερείται οριστικά την ευκαιρία να ”μάθει” από αυτά. Στην προσέγγιση K-Fold, κάθε παρατήρηση του αρχικού συνόλου θα χρησιμοποιηθεί ακριβώς μία φορά για έλεγχο και $k - 1$ φορές για εκπαίδευση. Αυτή η ανακύκλωση είναι σημαντική σε ιατρικά σύνολα δεδομένων, όπου ο αριθμός των παρατηρήσεων είναι συνήθως περιορισμένος και κάθε δεδομένο φέρει πολύτιμη πληροφορία. Ο απλός διαχωρισμός μάς παρέχει μόνο μια σημειακή εκτίμηση για την απόδοση του μοντέλου, αντιθέτως η διασταυρούμενη επικύρωση μάς παρέχει μια κατανομή k τιμών, επιτρέποντάς μας να υπολογίσουμε την τυπική απόκλιση. Αυτό μας προσφέρει διπλή πληροφορία, καθώς όχι μόνο

εκτιμούμε πόσο ακριβές είναι το μοντέλο (μέσω της μέσης τιμής), αλλά και πόσο σταθερό είναι σε μεταβολές των δεδομένων εκπαίδευσης (μέσω της τυπικής απόκλισης).

5 Επιλογή μεταβλητών (feature selection)

Στο παρόν κεφάλαιο θα διερευνήσουμε τη δυνατότητα απλοποίησης των μοντέλων και βελτίωσης της γενικευτικής τους ικανότητας μέσω της επιλογής ενός βέλτιστου υποσυνόλου χαρακτηριστικών.

5.1 Μέθοδος Φίλτρου

Για να διασφαλίσουμε την αξιοπιστία της επιλογής μας, εφαρμόσαμε δύο διαφορετικές τεχνικές μεθόδων φίλτρου: την αμοιβαία πληροφορία (Mutual Information) και τον Συντελεστή Συσχέτισης Pearson (Correlation) με τη μεταβλητή-στόχο. Η προσέγγιση αυτή είναι βέλτιστη, καθώς η συσχέτιση εντοπίζει τις ισχυρές γραμμικές εξαρτήσεις, ενώ η αμοιβαία πληροφορία αναδεικνύει μεταβλητές που μπορεί να έχουν πολύπλοκες, μη-γραμμικές σχέσεις με τον στόχο. Υπολογίσαμε και τα δύο σκορ για κάθε μεταβλητή του προεπεξεργασμένου συνόλου εκπαίδευσης και τα συνδυάσαμε για να έχουμε μια σφαιρική εικόνα της σημαντικότητας των χαρακτηριστικών.

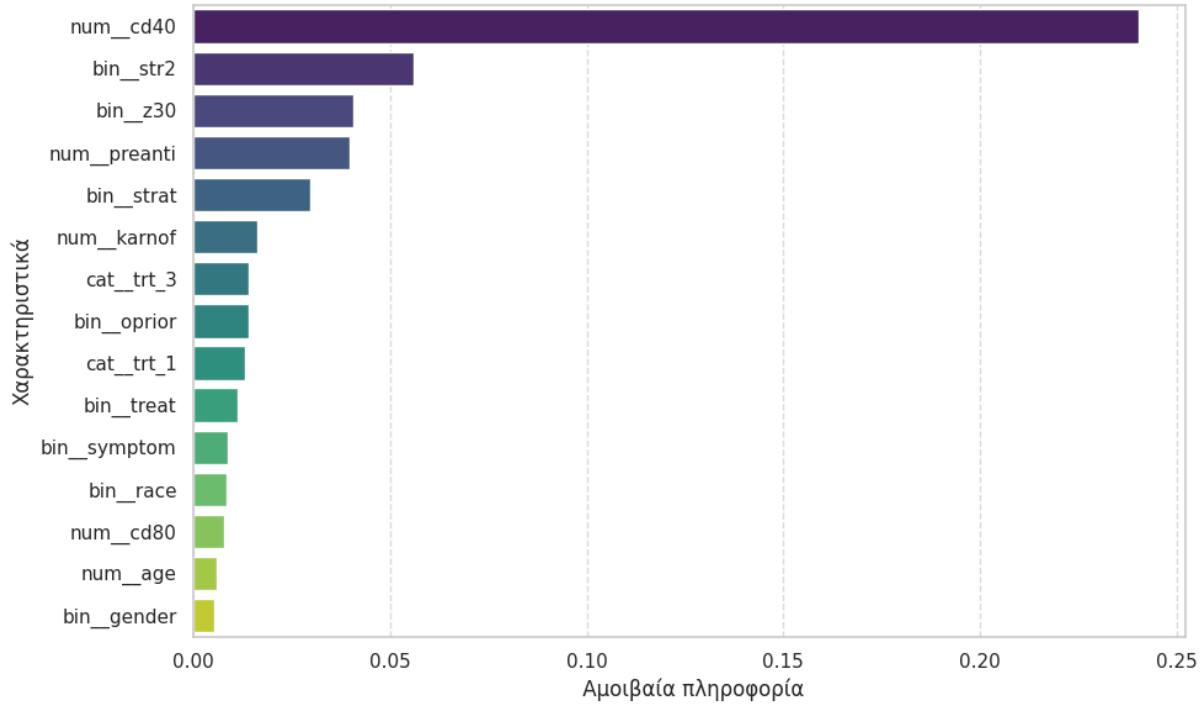
Πίνακας 3: Σημαντικότητα χαρακτηριστικών

Χαρακτηριστικό	**Mutual Information**	**Absolute Correlation**
num__cd40	0.2404	0.5761
bin__str2	0.0560	0.2318
bin__z30	0.0407	0.2196
num__preanti	0.0397	0.1515
bin__strat	0.0297	0.2199
num__karnof	0.0164	0.0969
bin__oprior	0.0140	0.0938
cat__trt_3	0.0140	0.0124
cat__trt_1	0.0131	0.1247
bin__treat	0.0113	0.1358
bin__symptom	0.0088	0.1208
bin__race	0.0088	0.0474
num__cd80	0.0080	0.0642
num__age	0.0061	0.0480
bin__gender	0.0053	0.0137
bin__drugs	0.0045	0.0100
num__wtkg	0.0000	0.0021
bin__homo	0.0000	0.0243
bin__hemo	0.0000	0.0652
cat__trt_2	0.0000	0.0003

Από τον Πίνακα 3 προκύπτει ότι η αρχική μέτρηση των κυττάρων CD4 (cd40) αποτελεί τον ισχυρότερο προγνωστικό παράγοντα, κυριαρχώντας τόσο στο σκορ αμοιβαίας πληροφορίας όσο και στη Γραμμική Συσχέτιση. Αντίθετα, εντοπίστηκε ένα υποσύνολο μεταβλητών (όπως το wtkg, η σεξουαλική προτίμηση (homo) και άλλες δυαδικές μεταβλητές συμπεριφοράς) με μηδενικό σκορ αμοιβαίας πληροφορίας. Οι μεταβλητές αυτές δεν φέρουν προγνωστική αξία για τη μεταβλητή-στόχο και η αφαίρεσή τους αναμένεται να μειώσει τον θόρυβο και να ενισχύσει την απλότητα του μοντέλου.

Προκειμένου να αποκτήσουμε μια πιο σαφή και άμεση εικόνα της σημαντικότητας των χαρακτηριστικών που αναλύθηκαν παραπάνω, προχωρήσαμε στην οπτικοποίηση των αποτελεσμάτων της αμοιβαίας πληροφορίας (Mutual

Information). Στο ραβδόγραμμα που ακολουθεί παρουσιάζουμε την ιεραρχική κατάταξη των μεταβλητών, αναδεικνύοντας οπτικά το μέγεθος της προγνωστικής αξίας που φέρει το κάθε χαρακτηριστικό για τη μεταβλητή-στόχο.



Σχήμα 7: Score mutual information

Από το Σχήμα 7 προκύπτουν ξεκάθαρα συμπεράσματα σχετικά με την προγνωστική ικανότητα των χαρακτηριστικών: Η αρχική μέτρηση των κυττάρων CD4 (num__cd40) αποτελεί με τεράστια διαφορά τον πιο κρίσιμο προγνωστικό παράγοντα για τη μεταβλητή-στόχο. Η μπάρα του χαρακτηριστικού αυτού (κοντά στο 0.24) επιβεβαιώνει τη στενή βιολογική και στατιστική σχέση της αρχικής κατάστασης του ανοσοποιητικού με τη μελλοντική εξέλιξή του. Ακολουθεί μια μικρή ομάδα χαρακτηριστικών (όπως τα bin__str2, bin__z30, num__preanti και bin__strat) με μέτρια συνεισφορά (σκορ μεταξύ 0.03 και 0.06). Αυτές οι μεταβλητές, αν και υπολείπονται σημαντικά του cd40, προσφέρουν χρήσιμη συμπληρωματική πληροφορία στο μοντέλο.

Η πλειοψηφία των υπόλοιπων χαρακτηριστικών καταγράφει σκορ κάτω του 0.02, σχηματίζοντας μια ”ουρά” στο γράφημα. Η σχεδόν μηδενική αμοιβαία πληροφορία τους υποδεικνύει ότι εισάγουν κυρίως θόρυβο και η ενδεχόμενη αφαίρεσή τους στα επόμενα στάδια (feature selection) αναμένεται να απλοποιήσει τα μοντέλα μας χωρίς να θυσιαστεί η προβλεπτική τους ικανότητα.

5.2 Μέθοδος Περιτυλίγματος (Wrapper Method): Recursive Feature Elimination (RFE)

Ως επόμενη τεχνική επιλογής, εφαρμόσαμε την Αναδρομική Απαλοιφή Χαρακτηριστικών (RFE), η οποία ανήκει στην κατηγορία των μεθόδων περιτυλίγματος. Σε αντίθεση με τις μεθόδους φίλτρου, η RFE χρησιμοποιεί έναν αλγόριθμο μηχανικής μάθησης στον πυρήνα της —στην περίπτωσή μας επιλέχθηκε η Γραμμική Παλινδρόμηση, δεδομένης της εξαιρετικής και σταθερής της απόδοσης στα baseline μοντέλα— προκειμένου να αξιολογήσει την πραγματική συνεισφορά κάθε μεταβλητής στην πρόβλεψη.

Η διαδικασία ξεκινά με όλα τα διαθέσιμα χαρακτηριστικά, εκπαιδεύει το μοντέλο και αφαιρεί επαναληπτικά το λιγότερο σημαντικό χαρακτηριστικό (βάσει των βαρών του μοντέλου), έως ότου καταλήξει στο βέλτιστο υποσύνολο. Για τον πειραματισμό μας, ρυθμίσαμε τον αλγόριθμο να επιλέξει αυστηρά τα 10 κορυφαία χαρακτηριστικά, αποσκοπώντας στη δημιουργία ενός πιο απλού, γρήγορου και ερμηνεύσιμου μοντέλου, απαλλαγμένου από τον θόρυβο.

Πίνακας 4: Επιλεγμένα χαρακτηριστικά με τη μέθοδο RFE

Χαρακτηριστικό	**Επιλέχθηκε**	**Κατάταξη (Ranking)**
num__cd40	True	1
num__cd80	True	1
cat__trt_1	True	1
bin__hemo	True	1
bin__oprior	True	1
bin__z30	True	1
bin__race	True	1
bin__str2	True	1
bin__symptom	True	1
bin__treat	True	1
num__karnof	False	2
bin__drugs	False	3
cat__trt_3	False	4
num__age	False	5
num__wtkg	False	6

Ο πίνακας 4 παρουσιάζει την τελική ιεράρχηση όλων των χαρακτηριστικών βάσει της μεθόδου RFE. Από τα αποτελέσματα μπορούμε να καταλήξουμε στα εξής συμπεράσματα: Οι πρώτες 10 μεταβλητές έλαβαν την κατάταξη 1, υποδεικνύοντας ότι αποτελούν τον βέλτιστο συνδυασμό για την πρόβλεψη του αριθμού των κυττάρων CD4. Αξιοσημείωτο είναι ότι ο αλγόριθμος επέλεξε να διατηρήσει μεταβλητές όπως το bin__hemo και το bin__race, οι οποίες παρόλο που είχαν χαμηλή μεμονωμένη συσχέτιση (filter methods), φαίνεται να προσφέρουν σημαντική συνδυαστική πληροφορία όταν λειτουργούν μαζί με τα υπόλοιπα χαρακτηριστικά. Οι υπόλοιπες μεταβλητές απορρίφθηκαν διαδοχικά από το μοντέλο. Για παράδειγμα, η μεταβλητή num__karnof (Rank 2) ήταν η τελευταία που αφαιρέθηκε πριν την οριστικοποίηση της 10άδας, ενώ μεταβλητές όπως η ηλικία (num__age) και το βάρος (num__wtkg) κατέλαβαν τις τελευταίες θέσεις (Rank 5 και 6 αντίστοιχα). Η απόρριψη των μεταβλητών με χαμηλή κατάταξη επιτρέπει στο μοντέλο να εστιάσει στα ”κρίσιμα” δεδομένα, μειώνοντας την πολυπλοκότητα και την πιθανότητα υπερπροσαρμογής (overfitting). Η επιλογή αυτή θέτει τις βάσεις για τη δημιουργία ενός πιο ερμηνεύσιμου και σταθερού μοντέλου.

5.3 Σύγκριση Απόδοσης Μοντέλου

Στόχος μας είναι να αξιολογήσουμε αν η δραστική μείωση της διαστατικότητας των δεδομένων (από 20 σε 10 χαρακτηριστικά) επηρεάζει την προβλεπτική ικανότητα του μοντέλου. Για τη σύγκριση χρησιμοποιήσαμε τον αλγόριθμο της Γραμμικής Παλινδρόμησης, ο οποίος εκπαιδεύτηκε και αξιολογήθηκε μέσω διασταυρούμενης επικύρωσης (5-fold cross-validation) σε δύο σενάρια: αρχικά με το πλήρες σύνολο των διαθέσιμων χαρακτηριστικών και στη συνέχεια αποκλειστικά με το υποσύνολο που προέκυψε από τη μέθοδο RFE. Τα αποτελέσματα της σύγκρισης, βάσει των μετρικών R^2 και MAE, παρατίθενται στη συνέχεια.

Πίνακας 5: Σύγκριση απόδοσης Γραμμικής Παλινδρόμησης

Μοντέλο / Σενάριο	**Χαρακτηριστικά**	**Mean R^2**	**Mean MAE**
Γραμμική Παλινδρόμηση (πλήρες)	20	0.3779	84.7081
Γραμμική Παλινδρόμηση (RFE)	10	0.3812	84.3959

Από τον πίνακα 5 έχουμε ότι: Στο πρώτο σενάριο, το μοντέλο εκπαιδεύτηκε με το πλήρες σύνολο των 20 χαρακτηριστικών, επιτυγχάνοντας Μέσο R^2 = 0.3779 και Μέσο MAE = 84.7081. Στο δεύτερο σενάριο, εκπαιδεύτηκε

αποκλειστικά με το υποσύνολο των 10 χαρακτηριστικών που επιλέχθηκαν από τη μέθοδο RFE, επιτυγχάνοντας βελτιωμένη επίδοση με Μέσο R^2 = 0.3812 και Μέσο MAE = 84.3959.

5.4 Σχολιασμός αποτελεσμάτων επιλογής μεταβλητών

Η διαδικασία επιλογής μεταβλητών οδήγησε σε σημαντικά οφέλη. Η προβλεπτική ικανότητα του μοντέλου όχι απλώς διατηρήθηκε αλλά παρουσίασε βελτίωση. Το σφάλμα (MAE) μειώθηκε και η ερμηνευτική ικανότητα (R^2) αυξήθηκε. Αυτό αποδεικνύει περίτρανα ότι τα 10 χαρακτηριστικά που απορρίφθηκαν αποτελούσαν θόρυβο και υποβάθμιζαν τη γενικευτική ικανότητα του αλγορίθμου. Ακόμη, η πολυπλοκότητα του μοντέλου μειώθηκε δραστικά, καθώς πλέον απαιτεί 50% λιγότερα δεδομένα εισόδου (10 αντί για 20 μεταβλητές), αυτή η μείωση κάνει το μοντέλο πιο ελαφρύ, ταχύτερο στην εκπαίδευση και λιγότερο επιρρεπές στην υπερπροσαρμογή (overfitting). Η αφαίρεση περιττών μεταβλητών βελτίωσε την ερμηνευσιμότητα. Σε ένα ιατρικό πρόβλημα, είναι πολύ πιο εφικτό και ασφαλές για έναν κλινικό ιατρό να ερμηνεύσει τον αντίκτυπο 10 στοχευμένων δεικτών επί της τελικής πρόβλεψης, παρά να προσπαθεί να κατανοήσει έναν συνδυασμό 20 παραμέτρων, πολλές εκ των οποίων (όπως το βάρος) αποδείχθηκαν στατιστικά ασήμαντες.

6 Ρύθμιση υπερπαραμέτρων (hyperparameter tuning)

Στο παρόν κεφάλαιο, εστιάζουμε στη βελτιστοποίηση της αρχιτεκτονικής των επιλεγμένων μοντέλων μέσω της ρύθμισης των υπερπαραμέτρων τους. Στόχος μας είναι η μετακίνηση από τη βασική υλοποίηση σε μια μορφή η οποία θα ελαχιστοποιεί το γενικευτικό σφάλμα. Οι υπερπαράμετροι καθορίζουν τη δομή και τη συμπεριφορά του αλγορίθμου, επηρεάζοντας άμεσα την ικανότητα του μοντέλου να μην οδηγείται σε υπερπροσαρμογή.

6.1 Επιλογή των δύο καλύτερων μοντέλων

Με βάση τα αποτελέσματα της αξιολόγησης στην ενότητα 4 αλλά και τη διερεύνηση της σημαντικότητας των χαρακτηριστικών στην ενότητα 5, προχωρούμε στη βελτιστοποίηση των δύο κορυφαίων αλγορίθμων που επιδέχονται παραμετροποίηση. Παρόλο που η Γραμμική Παλινδρόμηση παρουσίασε εξαιρετική σταθερότητα, η φύση της είναι παραμετρική και δεν διαθέτει υπερπαραμέτρους προς αναζήτηση . Άρα, επιλέγουμε προς βελτιστοποίηση τον Gradient Boosting Regressor και τον Random Forest Regressor. Οι αλγόριθμοι αυτοί, βασιζόμενοι σε δέντρα απόφασης (boosting και bagging αντίστοιχα), προσφέρουν μεγάλο εύρος παραμετροποίησης που μπορεί να οδηγήσει σε σημαντική βελτίωση της ακρίβειας.

6.2 Grid Search

Για τη βελτιστοποίηση της γενικευτικής ικανότητας των μοντέλων μας, εφαρμόσαμε τη μέθοδο Grid Search σε συνδυασμό με 5-fold Cross-Validation. Η επιλογή της Grid Search βασίστηκε στην ανάγκη μας για μια διερεύνηση του χώρου των υπερπαραμέτρων, η οποία να διασφαλίζει τον εντοπισμό του βέλτιστου συνδυασμού εντός των ορίων που θέσαμε.

Κατά τη διαδικασία αυτή, κάθε υποψήφιος συνδυασμός υπερπαραμέτρων αξιολογήθηκε πέντε φορές, χρησιμοποιώντας σε κάθε επανάληψη διαφορετικό τμήμα των δεδομένων ως validation set. Η προσέγγιση αυτή ελαχιστοποιεί την πιθανότητα η απόδοση του μοντέλου να οφείλεται σε μια ευνοϊκή τυχαία κατανομή των δεδομένων στο training set (overfitting των υπερπαραμέτρων). Ως αντικειμενική συνάρτηση για την επιλογή του βέλτιστου μοντέλου ορίσαμε την ελαχιστοποίηση του Μέσου Απόλυτου Σφάλματος (MAE).

6.3 Περιγραφή χώρου αναζήτησης

Για τον εντοπισμό της βέλτιστης αρχιτεκτονικής, ορίσαμε έναν χώρο αναζήτησης υπερπαραμέτρων (hyperparameter grid) και για τα δύο μοντέλα. Εξετάσαμε το πλήθος των δέντρων (n_estimators: 100, 200), τον ρυθμό μάθησης (learning_rate: 0.01, 0.05, 0.1) , το μέγιστο βάθος (max_depth: 3, 4, 5) για τον έλεγχο της πολυπλοκότητας, και το ποσοστό δειγματοληψίας (subsample: 0.8, 1.0) για την εισαγωγή στοχαστικότητας και την αποφυγή υπερπροσαρμογής.

Επικεντρωθήκαμε στο μέγεθος του δάσους (n_estimators: 100, 200, 300), στον περιορισμό της ανάπτυξης των δέντρων (max_depth: None, 10, 20), στον ελάχιστο αριθμό δειγμάτων για διάσπαση κόμβου (min_samples_split: 2, 5), καθώς και στη στρατηγική επιλογής χαρακτηριστικών σε κάθε διάσπαση (max_features: 'sqrt', 'log2').

6.4 Βέλτιστες υπερπαράμετροι και σύγκριση επιδόσεων

Η διαδικασία ελέγχου (μέσω 5-Fold Cross-Validation) επέστρεψε τους εξής βέλτιστους συνδυασμούς:

Για το Gradient Boosting, το μοντέλο βελτιστοποιήθηκε με learning_rate = 0.05, max_depth = 3, n_estimators = 100, και subsample = 0.8.

Για το Random Forest, η βέλτιστη απόδοση επετεύχθη με max_depth = 10, max_features = 'sqrt', min_samples_split = 5, και n_estimators = 300.

Πίνακας 6: Αποτελέσματα βελτιστοποίησης υπερπαραμέτρων (Grid Search)

Μοντέλο	**Βέλτιστες υπερπαράμετροι**	**MAE (πριν)**	**MAE (μετά)**
Gradient Boosting	learning_rate: 0.05, max_depth: 3, n_estimators: 100, subsample: 0.8	85.25	**84.19**
Random Forest	max_depth: 10, max_features: 'sqrt', min_samples_split: 5, n_estimators: 300	87.71	**84.90**

Τα αποτελέσματα της βελτιστοποίησης συνοψίζονται στον Πίνακα 6. Όπως παρατηρούμε, το MAE του Gradient Boosting μειώθηκε από 85.25 (baseline) σε 84.19, ενώ του Random Forest παρουσίασε ακόμα μεγαλύτερη πτώση, από 87.71 (baseline) σε 84.90.

6.5 Σχολιασμός της βελτίωσης

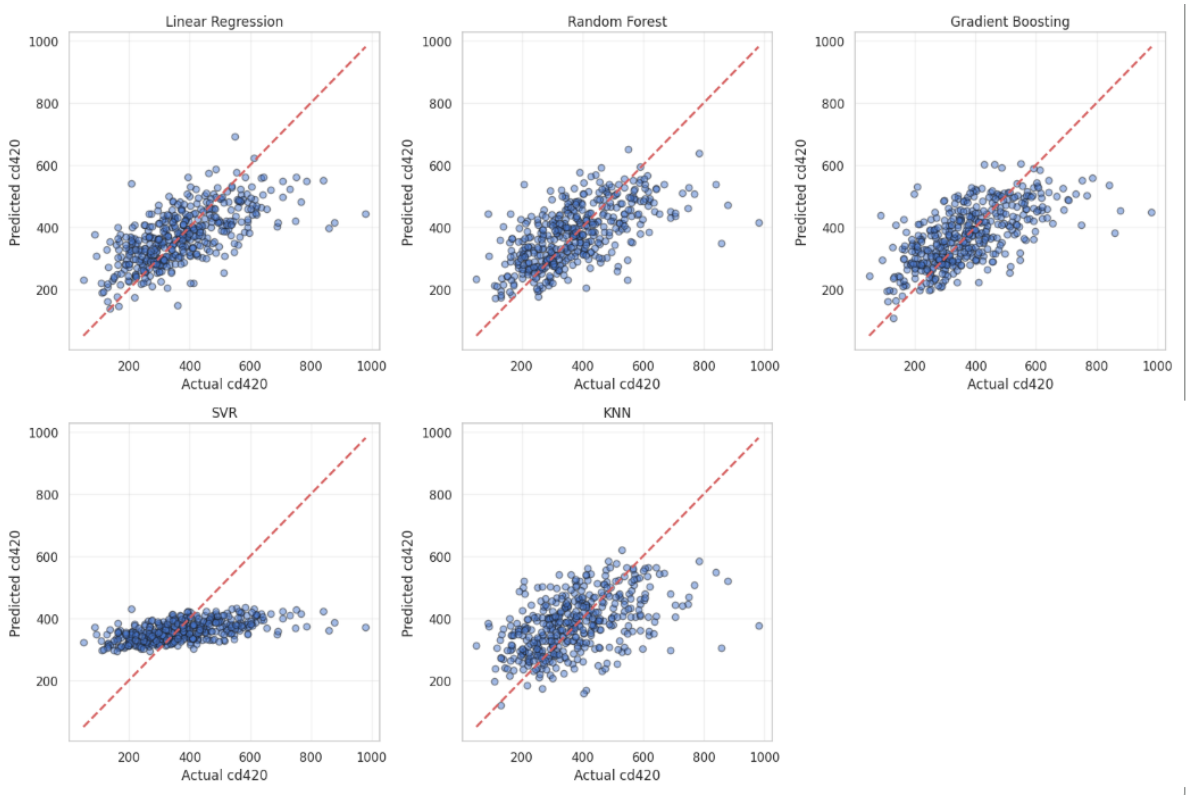
Η βελτίωση που παρατηρούμε μπορεί να χαρακτηριστεί ως οριακή, κάτι που αναμέναμε καθώς έχουμε ensemble αλγορίθμους που βασίζονται σε δέντρα απόφασης, οι οποίοι τείνουν να έχουν ήδη ισχυρή απόδοση με τις default ρυθμίσεις. Ωστόσο, η βελτιστοποίηση προσέφερε σημαντικά ποιοτικά χαρακτηριστικά. Για παράδειγμα, στο Random Forest, ο περιορισμός του βάθους (max_depth=10) και η χρήση τετραγωνικής ρίζας για την επιλογή χαρακτηριστικών (max_features='sqrt') μείωσαν τη διακύμανση (variance) και το σφάλμα (κατά 2.8 μονάδες MAE). Αντίστοιχα, στο Gradient Boosting, η εισαγωγή υποδειγματοληψίας (subsample=0.8) έδωσε στο μοντέλο έναν "stochastic" χαρακτήρα, που σε συνδυασμό με ένα μικρότερο ρυθμό μάθησης (0.05), απέτρεψε την υπερπροσαρμογή στο training set, οδηγώντας στην καλύτερη γενίκευση (MAE = 84.19).

7 Ανάλυση σφαλμάτων και διαγνωστικοί έλεγχοι

Στο παρόν κεφάλαιο, διεξάγουμε μια διαγνωστική ανάλυση του βέλτιστου μοντέλου μας (Gradient Boosting Regressor). Η διαδικασία αυτή μας βοηθά να επαληθεύσουμε την αξιοπιστία των προβλέψεων. Θα εξετάσουμε τη σχέση μεταξύ πραγματικών και προβλεπόμενων τιμών, καθώς και τη στατιστική συμπεριφορά των καταλοίπων, προκειμένου να εντοπίσουμε πιθανές ασυμμετρίες, μη γραμμικότητες ή ακραίες παρατηρήσεις που επηρεάζουν τη γενικευτική ικανότητα του μοντέλου.

7.1 Διάγραμμα πραγματικών έναντι προβλεπόμενων τιμών

Ξεκινάμε με την οπτικοποίηση της συνολικής προσαρμογής του μοντέλου στο σύνολο ελέγχου. Το διάγραμμα πραγματικών έναντι προβλεπόμενων τιμών μας επιτρέπει να δούμε πόσο κοντά στην ιδανική ευθεία (y=x) βρίσκονται οι προβλέψεις μας και αν το μοντέλο υποεκτιμά ή υπερεκτιμά συστηματικά συγκεκριμένες περιοχές των δεδομένων.



Σχήμα 8: Πραγματικές έναντι προβλεπόμενες τιμές

Από το Σχήμα 8 παρατηρούμε ότι η Γραμμική Παλινδρόμηση παρουσιάζει την πιο αδύναμη εικόνα, τα σημεία σχηματίζουν ένα ευρύ, άμορφο ”σύννεφο” που αποτυγχάνει να ακολουθήσει την διαγώνιο ($y = x$). Το μοντέλο τείνει να προβλέπει τιμές κοντά στον μέσο όρο, αδυνατώντας να συλλάβει τη μεταβλητότητα των δεδομένων. Είναι προφανές ότι η γραμμική υπόθεση είναι ανεπαρκής για τη μοντελοποίηση της βιολογικής πολυπλοκότητας των CD4 κυττάρων.

Στο Random Forest τα σημεία βρίσκονται πολύ πιο κοντά στην κόκκινη διακεκομμένη γραμμή, αντανακλώντας υψηλότερη ακρίβεια. Ωστόσο, τα σημεία βρίσκονται κυρίως πάνω από τη διαγώνιο.Αυτό υποδεικνύει μια συστηματική αδυναμία του μοντέλου, το οποίο τείνει να προβλέπει υψηλότερες τιμές CD4 για ασθενείς που στην πραγματικότητα έχουν πολύ χαμηλό αριθμό. Για τον αλγορίθμο SVR, παρατηρούμε ότι προβλέπει αποτελεσματικά τον πυρήνα των μεσαίων τιμών, παρόλα αυτά, αποτυγχάνει πλήρως σε πιο ακραίες τιμές

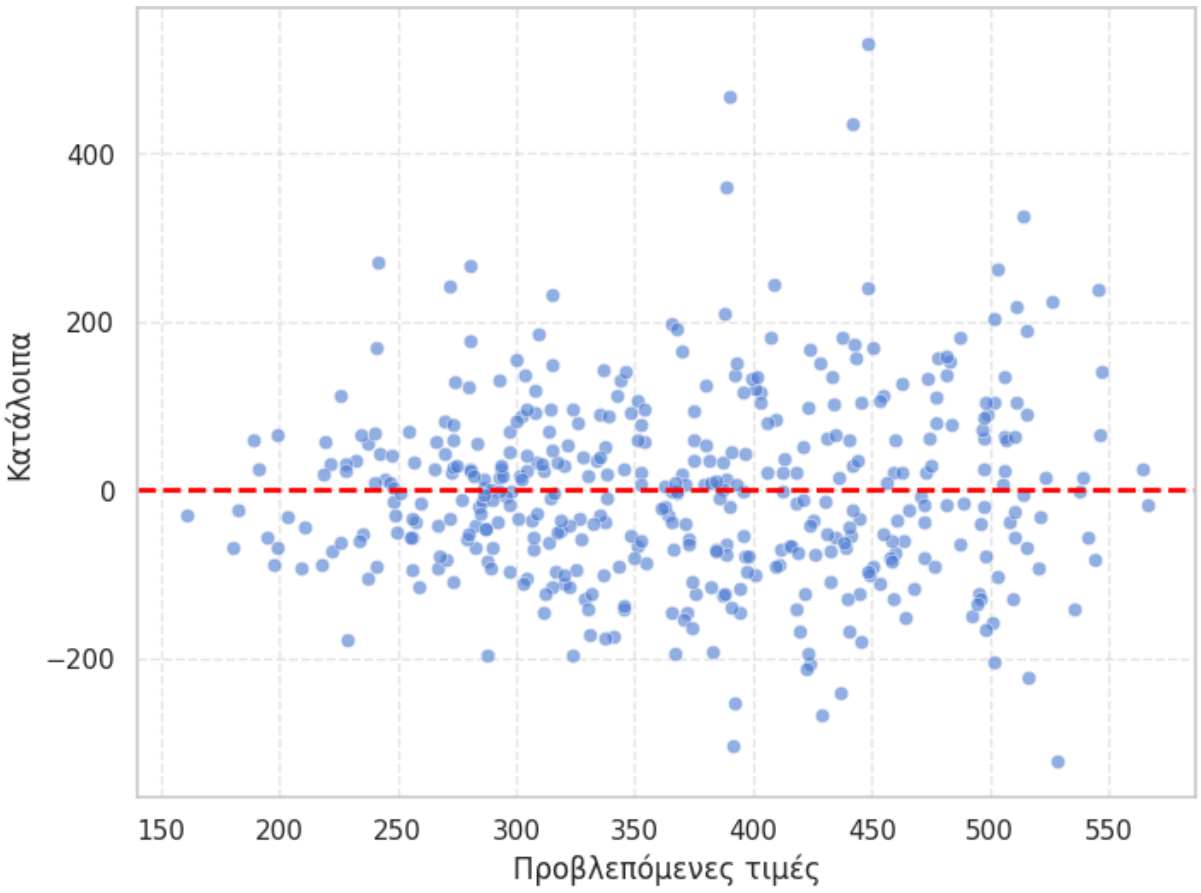
Η διαγνωστική εικόνα του αλγορίθμου KNN αναδεικνύει τους περιορισμούς των μεθόδων που βασίζονται σε μετρικές απόστασης (distance-based) σε πολύπλοκα ιατρικά προβλήματα. Το διάγραμμα διασποράς του KNN εμφανίζει έντονη απόκλιση από την διαγώνιο ($y = x$). Τα σημεία παρουσιάζουν σημαντική διασπορά, γεγονός που αντανακλά την αδυναμία του αλγορίθμου να ιεραρχήσει με ακρίβεια τη σημασία των διαφορετικών βιοδεικτών κατά τον υπολογισμό των ευκλείδειων αποστάσεων.

Στο Σχήμα 8 παρατηρούμε την προγνωστική ικανότητα του βέλτιστου μοντέλου στο test set (Gradient Boosting). Η κόκκινη διακεκομμένη ευθεία ($y = x$) αναπαριστά την ιδανική συνθήκη όπου οι προβλέψεις ταυτίζονται απόλυτα με τις πραγματικές μετρήσεις. Η ανάλυση της κατανομής των σημείων μας οδηγεί στα εξής συμπεράσματα:

Ενώ οι πραγματικές τιμές κυμαίνονται σε ένα ευρύ φάσμα (περίπου από 50 έως 1000), το μοντέλο τείνει να εξάγει προβλέψεις σε ένα πολύ στενότερο εύρος (κυρίως μεταξύ 200 και 600). Στο αριστερό άκρο του διαγράμματος (πραγματικές τιμές < 200), τα σημεία βρίσκονται σχεδόν εξ ολοκλήρου πάνω από την κόκκινη διαγώνιο. Αυτό υποδεικνύει μια συστηματική αδυναμία του μοντέλου, το οποίο τείνει να προβλέπει υψηλότερες τιμές CD4 για ασθενείς που στην πραγματικότητα έχουν πολύ χαμηλό αριθμό. Αντίστοιχα, στο δεξί άκρο (πραγματικές τιμές > 600), τα σημεία κατανέμονται σταθερά κάτω από τη διαγώνιο. Ο αλγόριθμος αποτυγχάνει να συλλάβει τις πολύ υψηλές εξάρσεις των κυττάρων CD4, εμφανίζοντας σημαντική υποεκτίμηση. Στο κεντρικό τμήμα της κατανομής (200-500), η προσαρμογή είναι καλύτερη, με τα σημεία να κατανέμονται εκατέρωθεν της ιδανικής ευθείας αν και εξακολουθεί να υφίσταται μεγάλη διασπορά. Η συμπεριφορά αυτή αποτελεί σύμπτωμα σε δεδομένα παλινδρόμησης με μεγάλο θόρυβο ή σε περιπτώσεις όπου τα διαθέσιμα χαρακτηριστικά δεν επαρκούν για να εξηγήσουν πλήρως τις ακραίες αποκλίσεις της μεταβλητής-στόχου. Ο αλγόριθμος, προκειμένου να ελαχιστοποιήσει το συνολικό του σφάλμα (MAE), επιλέγει να κάνει ασφαλείς προβλέψεις κοντά στον γενικό μέσο όρο, αποφεύγοντας τις ακραίες τιμές που θα μπορούσαν να καταλήξουν σε μεγάλα σφάλματα.

7.2-7.3 Μελέτη και Οπτικοποίηση καταλοίπων

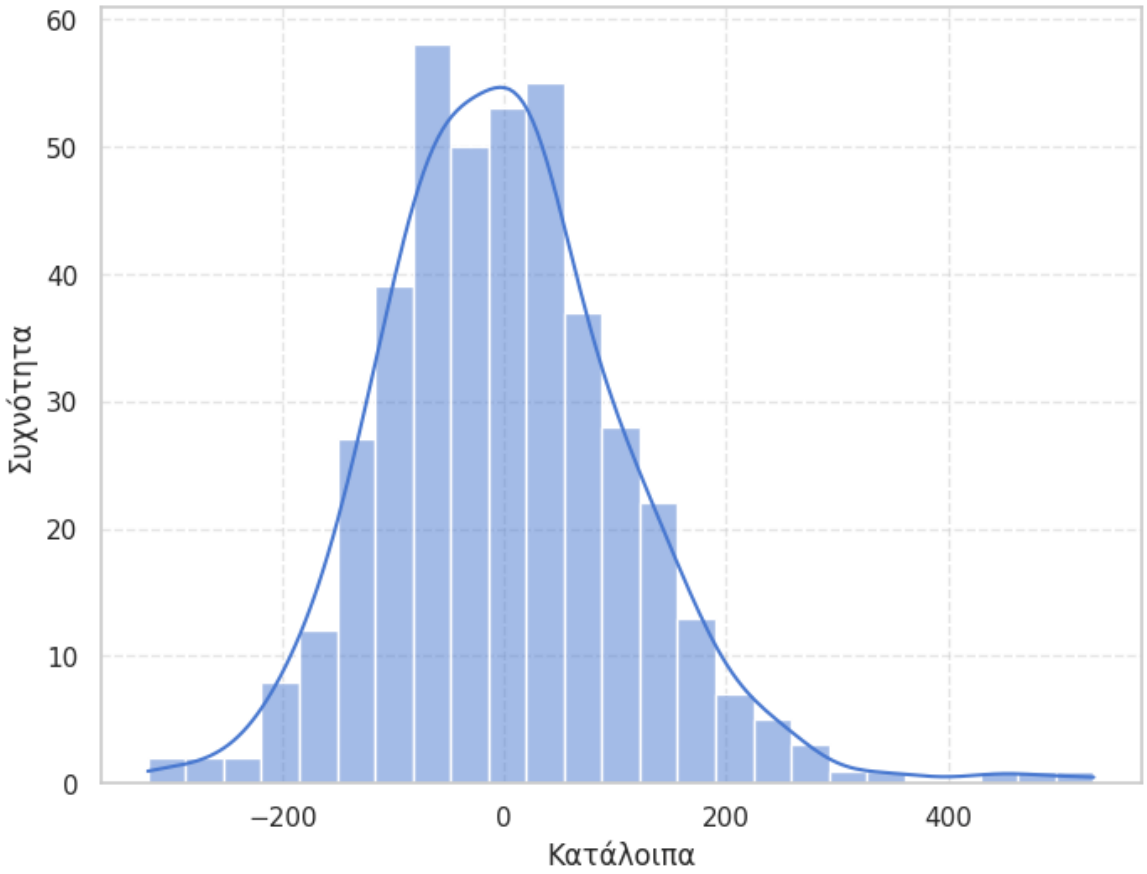
Για ένα εύρωστο μοντέλο, τα κατάλοιπα θα πρέπει να κατανέμονται τυχαία γύρω από το μηδέν, χωρίς να παρουσιάζουν εμφανή μοτίβα που να υποδηλώνουν πληροφορία που δεν αξιοποιήθηκε.



Σχήμα 9: Residual plot

Από το Σχήμα 9 παρατηρούμε ότι τα σημεία κατανέμονται σχετικά τυχαία γύρω από τον οριζόντιο άξονα. Αυτό αποδεικνύει ότι η αρχιτεκτονική του Gradient Boosting έχει καταφέρει να συλλάβει επιτυχώς τις περίπλοκες, μη γραμμικές συσχετίσεις μεταξύ των χαρακτηριστικών και της μεταβλητής-στόχου. Στο αριστερό και κεντρικό τμήμα του γραφήματος (για προβλέψεις από 150 έως 400), η διασπορά των καταλοίπων είναι συμμετρική και

σχετικά σταθερή. Ωστόσο, παρατηρούμε ότι καθώς αυξάνονται οι προβλεπόμενες τιμές (στο διάστημα 400-550), το πλήθος των σημείων τείνει να ανοίγει, εμφανίζοντας σημάδια ετεροσκεδαστικότητας. Το μοντέλο τείνει να έχει μεγαλύτερη αβεβαιότητα (και μεγαλύτερα σφάλματα) στις υψηλότερες προβλέψεις. Ακόμη, εντοπίζουμε σημεία με θετικά κατάλοιπα άνω του 300 ή και του 400. Δεδομένου ότι τα κατάλοιπα υπολογίζονται ως $Y_{true} - Y_{pred}$, αυτά τα μεγάλα θετικά σφάλματα αντιστοιχούν σε ασθενείς που είχαν απρόσμενα υψηλές πραγματικές μετρήσεις CD4, τις οποίες το μοντέλο υποεκτίμησε (προβλέποντας τιμές γύρω στο 400-450, ενώ η πραγματική τιμή ξεπερνούσε το 800-900).



Σχήμα 10: Κατανομή καταλοίπων

Από το Σχήμα 10 παρατηρούμε ότι η κατανομή είναι σαφώς κεντραρισμένη γύρω από το μηδέν, με την πλειονότητα των παρατηρήσεων συγκεντρώνεται στο διάστημα από -100 έως +100. Το γεγονός ότι ο μέσος όρος των σφαλμάτων προσεγγίζει το μηδέν υποδεικνύει ότι το μοντέλο λειτουργεί ισορροπημένα και δεν υπερεκτιμά ή υποεκτιμά τον αριθμό των κυττάρων CD4. Η γενική μορφή της κατανομής προσεγγίζει την κανονική κάτι που προσδίδει αξιοπιστία στο μοντέλο, καθώς μπορούμε να θεωρήσουμε τα κατάλοιπα ως τυχαίο θόρυβο. Ωστόσο παρά τη γενική κανονικότητα, παρατηρούμε ότι η δεξιά ”ουρά” της κατανομής είναι πιο τραβηγμένη σε σχέση με την αριστερή. Αυτό υποδηλώνει ότι τα outliers του μοντέλου προέρχονται από περιπτώσεις υποεκτίμησης, όπου η πραγματική τιμή CD4 του ασθενούς ήταν υψηλή αλλά το μοντέλο προέβλεψε μια πολύ πιο συγκρατημένη τιμή. Γενικά η κατανομή επιβεβαιώνει την ευρωστία του μοντέλου για τον γενικό πληθυσμό των δεδομένων, απομονώνοντας την ύπαρξη των μεγάλων σφαλμάτων σε ένα πολύ μικρό ποσοστό ακραίων και πιθανώς βιολογικά εξαιρετικών περιπτώσεων.

7.4 Έλεγχος σφαλμάτων

Βάσει των Σχημάτων 9, 10 δεν παρατηρούμε τάση υπερεκτίμησης ή υποεκτίμησης σε όλο το εύρος, αν και το μοντέλο τείνει να είναι πιο συντηρητικό στις ακραίες τιμές. Η απουσία καμπυλόγραμμου μοτίβου στο residual plot υποδηλώνει ότι ο Gradient Boosting αλγόριθμος κατάφερε να αποτυπώσει επιτυχώς τις μη γραμμικές σχέσεις των δεδομένων. Εντοπίζονται μεμονωμένα σημεία με κατάλοιπα που υπερβαίνουν τις 2 τυπικές αποκλίσεις, τα οποία χρήζουν περαιτέρω διερεύνησης ως προς την επίδρασή τους στη μέση επίδοση.

7.5 Εντοπισμός και ανάλυση παρατηρήσεων με μεγάλο σφάλμα

Προκειμένου να κατανοήσουμε τις αστοχίες του μοντέλου, απομονώνουμε τις τρεις παρατηρήσεις με το μεγαλύτερο απόλυτο σφάλμα στο test set.

Πίνακας 7: Οι 3 παρατηρήσεις με το μεγαλύτερο απόλυτο σφάλμα

Patient ID (pidnum)	**Πραγματική τιμή (CD4)**	**Πρόβλεψη**	**Απόλυτο σφάλμα**
1781	980	448.65	531.35
620	858	389.91	468.09
650	877	441.94	435.06

Μερικά απο τα χαρακτηριστικά των 3 αυτών ασθενών είναι:

Πίνακας 8: Προφίλ των τριών ασθενών με το μεγαλύτερο σφάλμα

Χαρακτηριστικό	**Ασθενής 1781**	**Ασθενής 620**	**Ασθενής 650**
Ηλικία (age)	40	32	30
Βάρος (wtkg)	93.67	80.51	97.30
Karnofsky Score (karnof)	90	100	90
Συμπτώματα (symptom)	0	0	0
Ιστορικό Αντιρετροϊκής θεραπείας (str2)	1	1	1
Θεραπεία (treat)	1	1	1
Αρχικό CD4 (cd40)	470	343	480
Αρχικό CD8 (cd80)	1510	1059	1320
Πραγματικό πλήθος CD4 στο τέλος (cd420)	**980**	**858**	**877**

Από τους Πίνακες 7, 8 μπορούμε να εξάγουμε κάποιες πληροφορίες για τους λόγους αστοχίας του αλγορίθμου. Παρατηρούμε ότι και στις τρεις περιπτώσεις το μοντέλο υπέπεσε σε μεγάλη υποεκτίμηση. Και οι τρεις ασθενείς διέθεταν εξαιρετική βασική υγεία (Karnofsky score 90-100), ενώ ξεκίνησαν με μέτρια αρχικά επίπεδα ανοσοποιητικού (CD40 από 343 έως 480), παρουσίασαν μεγάλη ανοσολογική βελτίωση στις 20 εβδομάδες διπλασιάζοντας σχεδόν τον αριθμό των κυττάρων τους. Η αδυναμία του μοντέλου να προβλέψει αυτές τις ακραία θετικές ανταποκρίσεις οφείλεται στη σύγκλιση τριών παραγόντων: Ως μοντέλο που βελτιστοποιήθηκε βάσει του Μέσου Σφάλματος (MAE), ο Gradient Boosting τείνει να εξάγει ασφαλείς προβλέψεις. Για έναν τυπικό ασθενή με αρχικό CD4 γύρω στο 400, η μέση αναμενόμενη αύξηση είναι συνήθως 50-100 κύτταρα, το μοντέλο απέφυγε την ακραία πρόβλεψη για να μην έχει ένα τεράστιο σφάλμα σε περίπτωση λανθασμένης εκτίμησης. Στο dataset απουσιάζουν μεταβλητές που θα μπορούσαν να βοηθήσουν τον αλγόριθμο να ξεχωρίσει έναν τυπικό ασθενή από έναν "super-responder", όπως η γενετική προδιάθεση, το ακριβές ιικό φορτίο προ θεραπείας ή η τέλεια προσήλωση στην αγωγή. Τιμές CD4 κοντά στο 900-1000 υποδεικνύουν ένα πλήρως υγιές ανοσοποιητικό σύστημα. Το μοντέλο, έχοντας εκπαιδευτεί κυρίως σε δεδομένα ανοσοκατασταλμένων ασθενών, στερείται επαρκών εκπαιδευτικών παραδειγμάτων σε αυτές τις ακραίες περιοχές τιμών.

Συμπερασματικά, τα μεγάλα αυτά σφάλματα δεν υποδηλώνουν αδυναμία του αλγορίθμου αλλά είναι απόρροια της

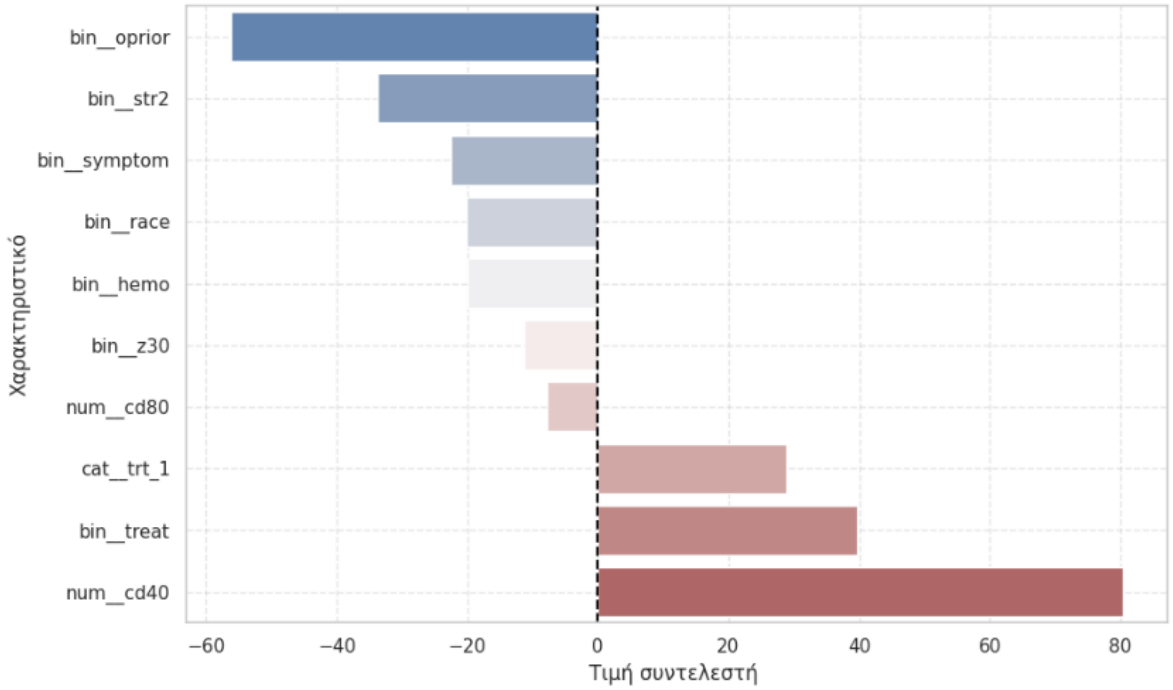
εγγενούς βιολογικής μεταβλητότητας και της έλλειψης των εξειδικευμένων χαρακτηριστικών που απαιτούνται για την πρόβλεψη σπάνιων και εξαιρετικά θετικών εκβάσεων.

8 Ερμηνευσιμότητα μοντέλου

Μετατοπίζουμε το ενδιαφέρον μας από την αξιολόγηση της προβλεπτικής απόδοσης στην ερμηνευσιμότητα των μοντέλων. Η υιοθέτηση ενός αλγορίθμου από την κλινική πράξη προϋποθέτει την πλήρη κατανόηση του μηχανισμού λήψης των αποφάσεών του. Στο κεφάλαιο αυτό, θα εξετάσουμε ποιες μεταβλητές καθοδηγούν τις προβλέψεις και πώς αλληλεπιδρούν μεταξύ τους, ξεκινώντας από την απόλυτη διαφάνεια των παραμετρικών γραμμικών μοντέλων και καταλήγοντας στην αποκωδικοποίηση των πολύπλοκων ensemble αλγορίθμων.

8.1 Σημασία των συντελεστών σε ένα γραμμικό μοντέλο

Η Πολλαπλή Γραμμική Παλινδρόμηση προσφέρει άμεση και εγγενή ερμηνευσιμότητα. Η σχέση μεταξύ των ανεξάρτητων μεταβλητών και της εξαρτημένης μεταβλητής (CD4 στις 20 εβδομάδες) εκφράζεται απευθείας μέσω της εξίσωσης του μοντέλου.
Το πρόσημο του συντελεστή υποδεικνύει την κατεύθυνση της επίδρασης. Ένα θετικό πρόσημο σημαίνει ότι η αύξηση της συγκεκριμένης μεταβλητής οδηγεί σε αύξηση του τελικού CD4 (άρα συνδέεται με καλύτερη ανοσολογική κατάσταση). Αντίθετα, ένα αρνητικό πρόσημο υποδηλώνει ότι η παρουσία ή η αύξηση του χαρακτηριστικού αυτού σχετίζεται με πτώση των CD4 κυττάρων. Δεδομένου ότι τα χαρακτηριστικά μας έχουν προηγουμένως τυποποιηθεί στο στάδιο της προεπεξεργασίας, όσο μεγαλύτερη είναι η απόλυτη τιμή του συντελεστή, τόσο ισχυρότερη είναι η επίδρασή του στην τελική πρόβλεψη. Κάθε συντελεστής εκφράζει την αναμενόμενη μεταβολή στην τιμή του CD4 για κάθε μία μονάδα αύξησης της αντίστοιχης μεταβλητής, υπό την προϋπόθεση ότι όλες οι υπόλοιπες μεταβλητές του μοντέλου παραμένουν σταθερές.



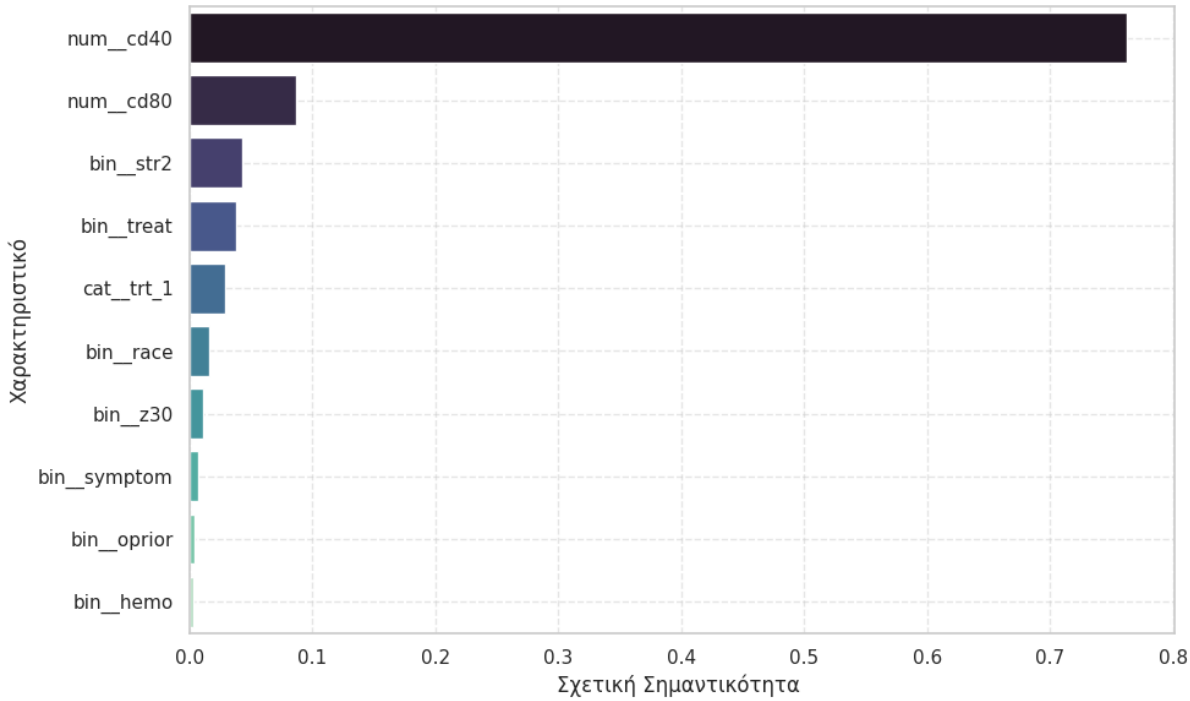
Σχήμα 11: Σημαντικότητα χαρακτηριστικών

Από το Σχήμα 11 παρατηρούμε ότι η μεταβλητή num__cd40 (Αρχικό CD4) διαθέτει τον μεγαλύτερο θετικό συντελεστή (+80). Αυτό είναι απολύτως αναμενόμενο, καθώς το βασικό επίπεδο του ανοσοποιητικού συστήμα-

τος πριν την έναρξη της μελέτης είναι ο ισχυρότερος δείκτης για τη μελλοντική του κατάσταση. Η λήψη της νέας θεραπευτικής αγωγής εμφανίζει ισχυρή θετική συσχέτιση, επιβεβαιώνοντας την αποτελεσματικότητα των φαρμάκων στην ανοσολογική ανασύσταση του ασθενούς (μεταβλητές bin__treat & cat__trt_1 (Δείκτες Θεραπείας)). Σχετικά με το ιστορικό προηγούμενων θεραπειών (bin__oprior & bin__str2), αποτελούν τους ισχυρότερους αρνητικούς παράγοντες (-55 και -35 αντίστοιχα). Κλινικά, ασθενείς με εκτεταμένο ιστορικό προηγούμενων αντιρετροϊκών φαρμάκων (πριν τη μελέτη) συνήθως φέρουν στελέχη του ιού με ανθεκτικότητα ή βρίσκονται σε πιο προχωρημένο στάδιο της νόσου, οδηγώντας σε μικρότερη ανταπόκριση στη νέα θεραπεία. Η ύπαρξη συμπτωμάτων (bin__symptom) κατά την έναρξη δρα ανασταλτικά, καθώς υποδηλώνει μεγαλύτερο ιικό φορτίο και πιο ταλαιπωρημένο οργανισμό. Καταλήγουμε ότι η Γραμμική Παλινδρόμηση καταφέρνει να μάθει τη βιολογική πραγματικότητα: η καλή αφετηρία και η νέα θεραπεία ανεβάζουν τα CD4, ενώ το βεβαρημένο ιατρικό ιστορικό και η συμπτωματολογία τα ρίχνουν.

8.2 Ερμηνευσιμότητα Ensemble μοντέλου (feature importance)

Για την καλύτερη κατανόηση της συμπεριφοράς του Gradient Boosting, το πρώτο βήμα είναι η εξαγωγή της εγγενούς σημαντικότητας χαρακτηριστικών (built-in feature importance). Σε αντίθεση με τα γραμμικά μοντέλα όπου εξετάζουμε συντελεστές, στα μοντέλα δέντρων η σημαντικότητα μετράται συνήθως με βάση το πόσο κάθε μεταβλητή μειώνει το σφάλμα (π.χ. Gini impurity) σε όλα τα δέντρα του ensemble.



Σχήμα 12: Σημαντικότητα χαρακτηριστικών

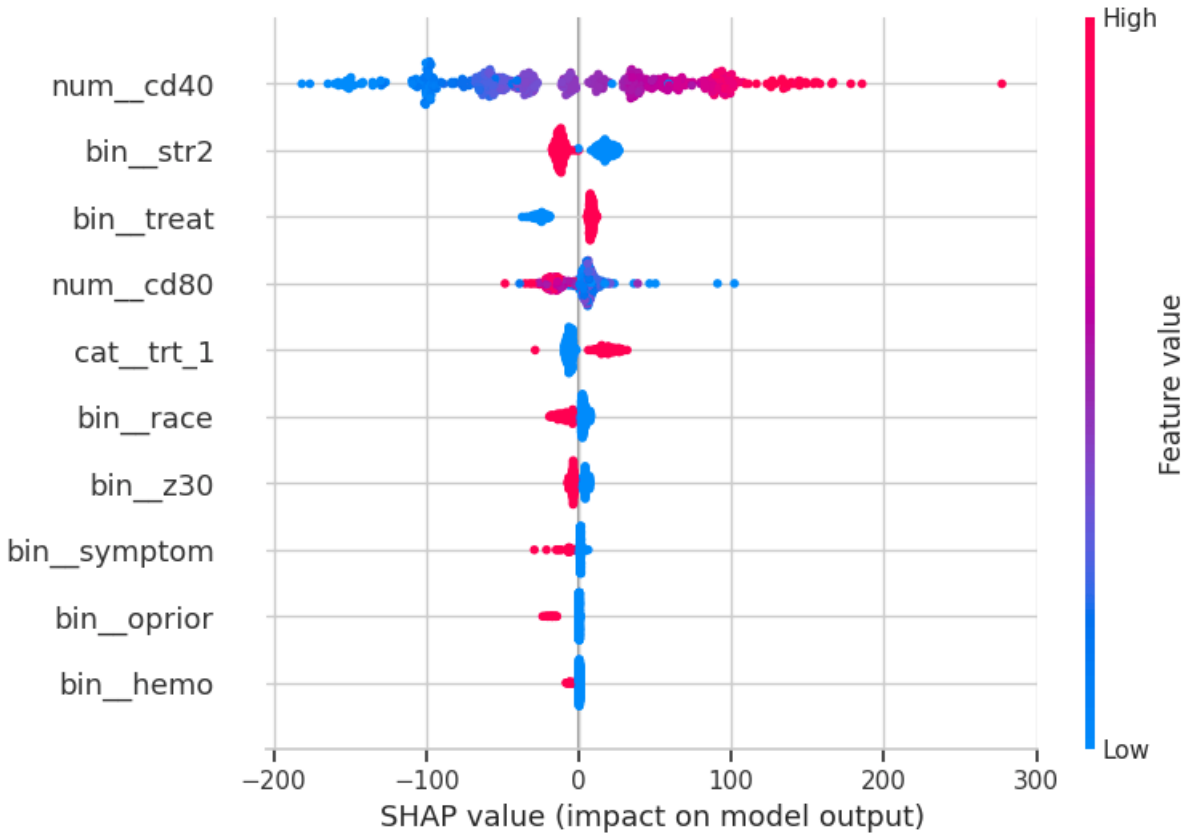
Όπως παρατηρούμε στο Σχήμα 12, το αρχικό επίπεδο των CD4 κυττάρων (num__cd40) κυριαρχεί απόλυτα ως ο πιο καθοριστικός παράγοντας για τις αποφάσεις του μοντέλου, με τη σχετική του σημαντικότητα να πλησιάζει το 0.8. Στη δεύτερη θέση ακολουθεί το αρχικό επίπεδο των CD8 κυττάρων (num__cd80), ενώ έπονται με μικρότερη αλλά ουσιαστική συνεισφορά μεταβλητές που σχετίζονται με το ιατρικό ιστορικό του ασθενούς (bin__str2) και τη λήψη νέας θεραπείας (bin__treat, cat__trt_1).

Αν και το διάγραμμα αυτό μας δείχνει ξεκάθαρα ποια χαρακτηριστικά είναι τα πιο χρήσιμα (global importance), δεν μας παρέχει πληροφορίες για την κατεύθυνση της επιρροής τους (εάν δηλαδή η αύξησή τους αυξάνει ή μειώνει την τελική πρόβλεψη). Για τον λόγο αυτό, στην επόμενη ενότητα προχωράμε σε μια πιο εξελιγμένη ανάλυση μέσω

των τιμών SHAP.

8.3-8.5 Ερμηνευσιμότητα Ensemble μοντέλου, SHAP values, SHAP summary plot, SHAP bar plot, Επίδραση μεταβλητών

Ενώ τα γραμμικά μοντέλα προσφέρουν εγγενή διαφάνεια, οι ισχυροί ensemble αλγόριθμοι, όπως ο Gradient Boosting που αναδείχθηκε ως το βέλτιστο μοντέλο της παρούσας μελέτης, λειτουργούν συχνά ως black boxes λόγω της πολύπλοκης μη γραμμικής αρχιτεκτονικής των πολλαπλών δέντρων απόφασης. Προκειμένου να αποκωδικοποιήσουμε τον μηχανισμό λήψης αποφάσεων του αλγορίθμου, αξιοποιούμε τη μέθοδο των τιμών SHAP. Η προσέγγιση αυτή, υπερτερεί των παραδοσιακών μεθόδων feature importance, καθώς δεν αξιολογεί μόνο το global importance μιας μεταβλητής αλλά υπολογίζει το local impact κάθε χαρακτηριστικού για κάθε μεμονωμένο ασθενή. Το SHAP Summary Plot που ακολουθεί, συνδυάζει τη σπουδαιότητα της μεταβλητής με την κατεύθυνση της επίδρασής της, προσφέροντας μια πλήρη κλινική απεικόνιση της συμπεριφοράς του μοντέλου.

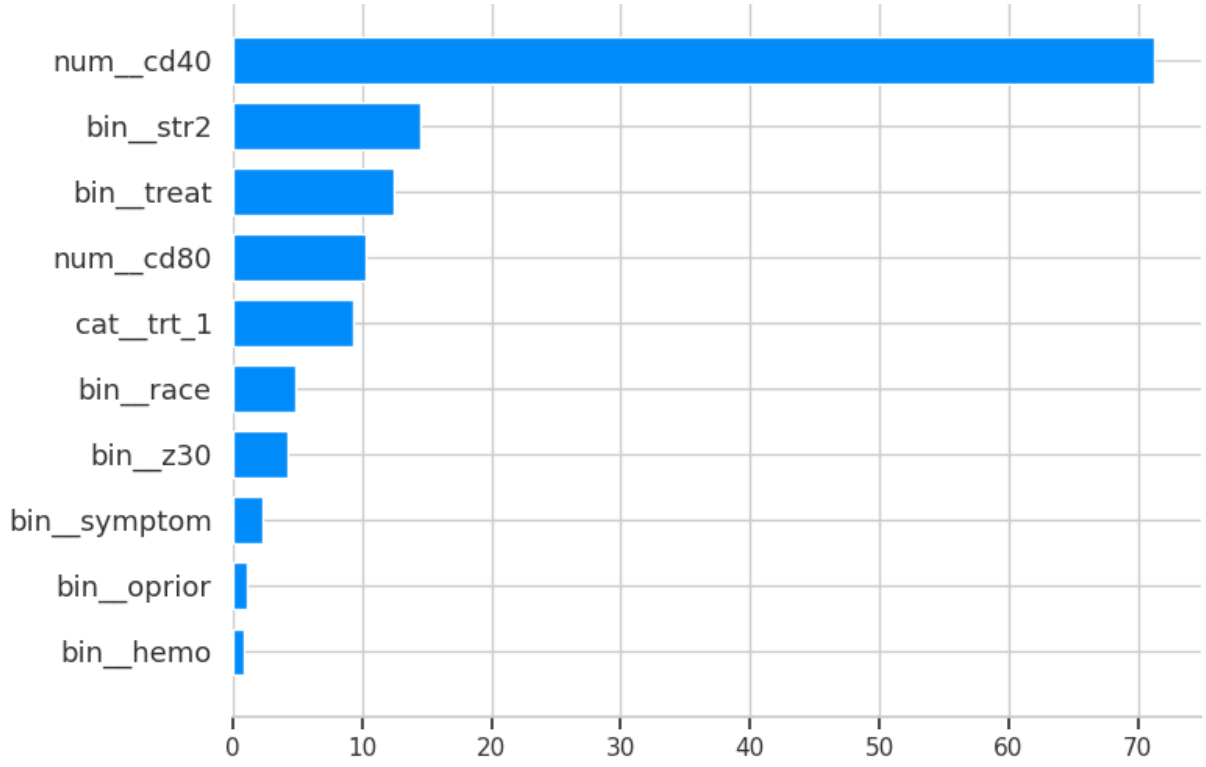


Σχήμα 13: SHAP Summary Plot (Gradient Boosting)

Το Σχήμα 13, μας προσφέρει μια πολυδιάστατη οπτικοποίηση της συμπεριφοράς του Gradient Boosting μοντέλου. Στον κατακόρυφο άξονα, οι μεταβλητές ταξινομούνται βάσει της συνολικής τους σπουδαιότητας (από την πιο σημαντική προς τη λιγότερο σημαντική). Στον οριζόντιο άξονα (SHAP value), αποτυπώνεται η θετική ή αρνητική επίδραση στην πρόβλεψη του τελικού CD4. Κάθε τελεία αντιπροσωπεύει έναν μεμονωμένο ασθενή, ενώ το χρώμα της (από μπλε έως κόκκινο) υποδηλώνει την πραγματική τιμή του εκάστοτε χαρακτηριστικού.

Από την ανάλυση του διαγράμματος μπορούμε να εξάγουμε τα ακόλουθα συμπεράσματα: Το αρχικό πλήθος CD40 κυττάρων (num__cd40) αποτελεί με διαφορά τον ισχυρότερο προγνωστικό παράγοντα. Οι κόκκινες τελείες (υψηλό αρχικό CD4) εκτείνονται έντονα προς τα δεξιά, προσθέτοντας σημαντική θετική αξία στην τελική πρόβλεψη. Αντίστοιχα, οι μπλε τελείες (χαμηλό αρχικό CD4) ωθούν την πρόβλεψη ισχυρά προς τα αριστερά (αρνητικές

SHAP values). Η μεγάλη διασπορά των σημείων υποδηλώνει τον κρίσιμο ρόλο αυτής της μεταβλητής στη διαμόρφωση της τελικής τιμής. Ως δεύτερος πιο σημαντικός παράγοντας αναδεικνύεται το ιστορικό λήψης αντιρετροϊκής αγωγής (bin__str2). Εδώ η σχέση είναι αντίστροφη, οι κόκκινες τελείες (παρουσία ιστορικού) συγκεντρώνονται στην αρνητική πλευρά του άξονα SHAP. Το μοντέλο "τιμωρεί" την πρόβλεψη για ασθενείς με προηγούμενη θεραπεία, κάτι που ιατρικά μεταφράζεται σε πιθανή ανθεκτικότητα του ιού ή πιο προχωρημένη νόσο.
Η χορήγηση της νέας αγωγής (bin__treat & cat__trt_1) λειτουργεί προστατευτικά. Οι κόκκινες τελείες βρίσκονται σταθερά στον θετικό άξονα SHAP, αποδεικνύοντας ότι το μοντέλο αναγνωρίζει την αποτελεσματικότητα της παρέμβασης στην αύξηση των κυττάρων CD4. Σε αντίθεση με το CD4, τα υψηλά επίπεδα CD8 (num__cd80) παρουσιάζουν αρνητικές τιμές SHAP, δηλαδή ωθούν την πρόβλεψη προς τα κάτω. Αυτό συνάδει με τη βιολογία του HIV, όπου η υπερβολική αύξηση των κυτταροτοξικών Τ-κυττάρων (CD8) υποδηλώνει συχνά έντονη ιική αντιγραφή και χρόνια ανοσολογική ενεργοποίηση (immune activation), η οποία οδηγεί σε ταχύτερη καταστροφή των CD4. Μεταβλητές όπως η παρουσία συμπτωμάτων (bin__symptom) και το ιστορικό λήψης ZDV (bin__oprior) δρουν αρνητικά , επιβεβαιώνοντας τη γενικότερη κλινική εικόνα πως ένας ήδη επιβαρυμένος οργανισμός θα έχει πιο περιορισμένη ανοσολογική ανασύσταση.
Συμπερασματικά, Η ανάλυση SHAP αποδεικνύει ότι ο ensemble αλγόριθμος, παρότι πολύπλοκος (black box), δεν εντόπισε απλώς τυχαία στατιστικά μοτίβα αλλά έμαθε την υποκείμενη βιολογία της λοίμωξης HIV. Οι αποφάσεις του ευθυγραμμίζονται πλήρως τόσο με τα ευρήματα της Γραμμικής Παλινδρόμησης όσο και με την εδραιωμένη ιατρική γνώση.
Ενώ το διάγραμμα σύνοψης (Summary Plot) μας προσέφερε μια λεπτομερή, πολυδιάστατη οπτική της κατεύθυνσης και της διασποράς των επιδράσεων σε ατομικό επίπεδο , είναι εξίσου σημαντικό να αξιολογήσουμε τη συνολική βαρύτητα των μεταβλητών στο σύνολο του μοντέλου. Προκειμένου να απομονώσουμε το global importance κάθε χαρακτηριστικού από τον θόρυβο της εκάστοτε κατεύθυνσης, προχωράμε στην παρουσίαση του ραβδογράμματος SHAP (Bar Plot). Το γράφημα αυτό λειτουργεί συμπληρωματικά, εστιάζοντας αποκλειστικά στο μέσο απόλυτο μέγεθος της επιρροής κάθε μεταβλητής, παρέχοντας έτσι μια ξεκάθαρη και ποσοτικοποιημένη ιεράρχηση.



Σχήμα 14: SHAP Bar Plot (Gradient Boosting)

Στο Σχήμα 14 ο οριζόντιος άξονας αναπαριστά τη μέση απόλυτη τιμή SHAP, δηλαδή το μέσο μέγεθος της

μεταβολής που προκαλεί η εκάστοτε μεταβλητή στην τελική πρόβλεψη του μοντέλου (σε αριθμό κυττάρων CD4), ανεξαρτήτως του αν η επίδραση αυτή είναι αυξητική ή μειωτική. Μπορούμε να εξάγουμε τα ακόλουθα συμπεράσματα: Το αρχικό πλήθος CD40 κυττάρων (num__cd40) ξεχωρίζει από όλες τις υπόλοιπες, με τη μέση απόλυτη επίδρασή της να ξεπερνά τα 70 κύτταρα. Αυτό επιβεβαιώνει πως η αφετηριακή κατάσταση του ανοσοποιητικού συστήματος αποτελεί τον απόλυτο καθοδηγητή των προβλέψεων του δέντρου. Σε πολύ μικρότερη αλλά αξιοσημείωτη κλίμακα (με μέση επίδραση από 10 έως 15 κύτταρα), ακολουθεί μια ομάδα τεσσάρων κλινικών μεταβλητών. Σε αυτήν ανήκει το ιστορικό λήψης αντιρετροϊκής αγωγής (bin__str2), οι δείκτες της παρούσας θεραπευτικής παρέμβασης (bin__treat και cat__trt_1) και τα επίπεδα των κυτταροτοξικών Τ-κυττάρων (num__cd80).
Χαρακτηριστικά όπως η φυλή (bin__race), η παρουσία συμπτωμάτων (bin__symptom) και η αιμορροφιλία (bin__hemo), παρουσιάζουν ελάχιστη global συνεισφορά (κάτω από 5 κύτταρα). Ο αλγόριθμος τα χρησιμοποιεί πρακτικά για μικρο-διορθώσεις της τελικής πρόβλεψης και όχι ως βασικούς άξονες απόφασης. Συνολικά, το ραβδόγραμμα αποδεικνύει ότι το μοντέλο είναι εξαιρετικά εστιασμένο στα βασικά βιολογικά και φαρμακευτικά δεδομένα, αγνοώντας αποτελεσματικά τον θόρυβο από λιγότερο σημαντικά χαρακτηριστικά.

9 Σύγκριση απλών και σύνθετων μοντέλων

9.1 Σύγκριση γραμμικής παλινδρόμησης και Gradient Boosting

Κατά τη διάρκεια της παρούσας μελέτης, αναπτύξαμε και αξιολογήσαμε μοντέλα διαφορετικών επιπέδων πολυπλοκότητας. Από τη μία πλευρά, η Πολλαπλή Γραμμική Παλινδρόμηση (Linear Regression) αποτέλεσε το βασικό απλό μοντέλο αναφοράς. Το κύριο πλεονέκτημά της είναι η απλοϊκότητα στην κατανόηση της λειτουργίας του, η σχέση μεταξύ των μεταβλητών (όπως το αρχικό CD4 ή η λήψη θεραπείας) και του τελικού CD4 εκφράζεται γραμμικά, καθιστώντας τον αλγόριθμο πλήρως κατανοητό. Ωστόσο, η απλοϊκή της φύση και η αυστηρή υπόθεση της γραμμικότητας περιόρισαν την προβλεπτική της ικανότητα, καθώς αδυνατούσε να συλλάβει πολύπλοκες αλληλεπιδράσεις μεταξύ των βιολογικών χαρακτηριστικών.

Από την άλλη πλευρά, το μοντέλο Gradient Boosting αποτέλεσε τον εκπρόσωπο των σύνθετων, ensemble αλγορίθμων που δοκιμάσαμε. Χάρη στη μη γραμμική αρχιτεκτονική του και τη σταδιακή διόρθωση των σφαλμάτων μέσω πολλαπλών δέντρων απόφασης, κατέγραψε σαφώς ανώτερη προβλεπτική ακρίβεια, ελαχιστοποιώντας τα σφάλματα. Το τίμημα αυτής της ανώτερης απόδοσης ήταν η απώλεια της άμεσης ερμηνευσιμότητας, μετατρέποντας το μοντέλο σε ένα «μαύρο κουτί».

9.2 Ερμηνευσιμότητα vs προβλεπτική ακρίβεια

Σε μια κλινική εφαρμογή, η προβλεπτική ακρίβεια είναι ζωτικής σημασίας, καθώς μια λανθασμένη πρόβλεψη για την πορεία του ανοσοποιητικού συστήματος ενός ασθενούς με HIV μπορεί να οδηγήσει σε καθυστερημένη ή ακατάλληλη θεραπευτική παρέμβαση. Ωστόσο, η ερμηνευσιμότητα είναι και αυτή αρκετά σημαντική, διότι ένας ιατρός (και γενικότερα ένας επιστήμονας) δεν θα εμπιστευτεί και δεν θα υιοθετήσει ποτέ έναν αλγόριθμο εάν δεν μπορεί να κατανοήσει το επιστημονικό σκεπτικό πίσω από την πρόβλεψη. Επομένως, αναγνωρίζουμε πως το ιδανικό σύστημα πρέπει να είναι ταυτόχρονα ακριβές για να προστατεύει τον ασθενή και ερμηνεύσιμο για να υποστηρίζει τον ιατρό-επιστήμονα.

9.3 Τελική πρόταση και αιτιολόγηση

Λαμβάνοντας υπόψη τα παραπάνω δεδομένα, για τη χρήση σε μια πραγματική κλινική εφαρμογή προτείνουμε την επιλογή του σύνθετου μοντέλου Gradient Boosting, συνοδευόμενου υποχρεωτικά από το πλαίσιο ερμηνευσιμότητας SHAP.

Η αιτιολόγησή μας για αυτήν την επιλογή στηρίζεται στο γεγονός ότι η πολυπλοκότητα των πραγματικών ιατρικών και βιολογικών δεδομένων απαιτεί αλγορίθμους ικανούς να μοντελοποιούν σύνθετες, μη γραμμικές σχέσεις.

Σε προβλήματα αυτού του είδους, διαπιστώσαμε ότι σύγχρονες ensemble μέθοδοι, όπως το Gradient Boosting, επιτυγχάνουν αποδεδειγμένα μέγιστη προβλεπτική ακρίβεια συγκριτικά με τα απλά παραμετρικά μοντέλα. Επιπροσθέτως, η ενσωμάτωση πλαισίων ερμηνευσιμότητας, όπως οι τιμές SHAP, γεφυρώνουν το χάσμα μεταξύ απόδοσης και διαφάνειας, αναιρώντας πρακτικά το παραδοσιακό δίλημμα. Όπως καταδείξαμε και στην ανάλυσή μας, μπορούμε πλέον να ”ξεκλειδώσουμε” αυτά τα «μαύρα κουτιά» και να παρέχουμε πλήρη ανάλυση της τοπικής επίδρασης για κάθε μεμονωμένη περίπτωση ξεχωριστά. Σε πραγματικές συνθήκες εφαρμογής, ένα τέτοιο σύστημα δεν περιορίζεται στην παροχή μιας στείρας αριθμητικής πρόβλεψης αλλά παρέχει στους επαγγελματίες υγείας μια σαφή και οπτικοποιημένη εξήγηση, αναδεικνύοντας πώς συγκεκριμένοι προγνωστικοί παράγοντες (π.χ. η τρέχουσα κλινική εικόνα, η χορηγούμενη αγωγή ή το ιατρικό ιστορικό) συνδιαμόρφωσαν την τελική απόφαση του αλγορίθμου για τον εκάστοτε ασθενή.

Συμπερασματικά, καταλήγουμε ότι η μίξη ισχυρών προγνωστικών αλγορίθμων (Gradient Boosting) και σύγχρονων εργαλείων επεξηγήσιμης τεχνητής νοημοσύνης (SHAP) αποτελεί τη βέλτιστη πρακτική, διασφαλίζοντας τόσο την ασφάλεια όσο και την εμπιστοσύνη στη διαδικασία λήψης κλινικών αποφάσεων.

10 Αναπαραγωγιμότητα και πειραματικός σχεδιασμός

10.1 Εξασφάλιση αναπαραγωγιμότητας

Βασικός πυλώνας κάθε σύγχρονης επιστημονικής μελέτης στον τομέα της Μηχανικής Μάθησης είναι η ικανότητα τρίτων ερευνητών να αναπαράγουν ακριβώς τα ίδια αποτελέσματα (reproducibility). Για να διασφαλίσουμε την απόλυτη αναπαραγωγιμότητα των πειραμάτων μας, εφαρμόσαμε αυστηρές πρακτικές σε όλο το μήκος του κώδικα. Αρχικά, ορίσαμε μια σταθερή τιμή αρχικοποίησης (*random_state=30*) σε όλες τις στοχαστικές διαδικασίες. Αυτό περιλαμβάνει τον διαχωρισμό των δεδομένων σε σύνολα εκπαίδευσης και δοκιμής (train-test split), τη δειγματοληψία κατά το cross-validation, καθώς και την αρχικοποίηση των παραμέτρων στα ensemble μοντέλα (π.χ. Random Forest, Gradient Boosting). Επιπλέον, για να αποφύγουμε τη διαρροή πληροφορίας (data leakage) και να τυποποιήσουμε τη ροή εργασίας, δομήσαμε τη διαδικασία προεπεξεργασίας μέσα σε ένα ενιαίο, σαφές Pipeline (*scikit-learn Pipeline & ColumnTransformer*). Με αυτόν τον τρόπο, οι μετασχηματισμοί (όπως η τυποποίηση και το one-hot encoding) εκαπιδεύτικαν στις παραμέτρους τους αποκλειστικά από το training set και στη συνέχεια εφαρμόστηκαν αυτούσιες στο test set, εξασφαλίζοντας ότι η όλη διαδικασία είναι απολύτως διαφανής, αυτοματοποιημένη και επαναλήψιμη για οποιοδήποτε νέο δείγμα δεδομένων.

10.2 Περιορισμοί του Dataset

Παρά τα ενθαρρυντικά αποτελέσματα των μοντέλων μας, οφείλουμε να αναγνωρίσουμε ορισμένους περιορισμούς του συνόλου δεδομένων, οι οποίοι επηρεάζουν την αξιοπιστία των προβλέψεων:

- **Μικρό Μέγεθος:** Τα δεδομένα προέρχονται από κλινικές δοκιμές, οι οποίες εκ φύσεως διαθέτουν περιορισμένο αριθμό συμμετεχόντων (2.169 ασθενείς). Αν και επαρκές για παραδοσιακά μοντέλα μηχανικής μάθησης, το μέγεθος αυτό περιορίζει την ικανότητά μας να εκπαιδεύσουμε πιο περίπλοκες αρχιτεκτονικές (π.χ. Βαθιά Νευρωνικά Δίκτυα) χωρίς τον κίνδυνο overfitting.

- **Θόρυβος:** Οι ιατρικές μετρήσεις, όπως ο αριθμός των CD4 κυττάρων, υπόκεινται σε σημαντικές βιολογικές διακυμάνσεις από μέρα σε μέρα, ενδεχόμενα εργαστηριακά σφάλματα ή ανακρίβειες στην καταγραφή. Αυτός ο θόρυβος δημιουργεί ένα ανώτατο όριο στην προβλεπτική ικανότητα οποιουδήποτε αλγορίθμου.

- **Μεροληψία και περιορισμένη γενικευσιμότητα:** Το δείγμα προέρχεται από μια συγκεκριμένη κλινική δοκιμή περασμένων δεκαετιών (ACTG 175), με συγκεκριμένα δημογραφικά κριτήρια ένταξης και φαρμακευτικά πρωτόκολλα (όπως η μονοθεραπεία με ζιδοβουδίνη - ZDV). Συνεπώς, τα μοντέλα μας φέρουν μεροληψία

υπέρ αυτής της συγκεκριμένης ομάδας και ενδέχεται να μην μπορούν να γενικεύσουν με ακρίβεια σε σύγχρονους ασθενείς με HIV, οι οποίοι λαμβάνουν σύγχρονες, υψηλής δραστικότητας αντιρετροϊκές θεραπείες (HAART) ή ανήκουν σε διαφορετικά γεωγραφικά και ηλικιακά προφίλ.

10.3 Προτάσεις βελτίωσης για μελλοντική εργασία

Αναγνωρίζοντας τους παραπάνω περιορισμούς, προτείνουμε δύο βασικές κατευθύνσεις για τη βελτίωση και επέκταση της παρούσας έρευνας στο μέλλον. Αρχικά, για να αντιμετωπιστεί το πρόβλημα της γενικευσιμότητας, καθίσταται αναγκαία η ενσωμάτωση σύγχρονων πολυκεντρικών δεδομένων (multi-center data). Μια μελλοντική έρευνα θα πρέπει να εκπαιδεύσει και να επικυρώσει τα μοντέλα σε μεγάλα, σύγχρονα datasets από διάφορα νοσοκομεία. Η προσθήκη δεδομένων από ασθενείς που λαμβάνουν σύγχρονες θεραπείες, σε συνδυασμό με τεχνικές μεταφοράς μάθησης, θα καθιστούσε το εργαλείο έτοιμο για πραγματική κλινική χρήση. Εξίσου σημαντική είναι η στοχευμένη μηχανική χαρακτηριστικών. Ενώ στην παρούσα εργασία χρησιμοποιήσαμε τα χαρακτηριστικά στην αρχική τους μορφή, σε μελλοντική φάση και σε άμεση συνεργασία με ιατρούς-λοιμωξιολόγους, θα μπορούσαμε να συνθέσουμε νέους βιοδείκτες ανώτερου επιπέδου. Ένα χαρακτηριστικό παράδειγμα αποτελεί η δημιουργία του CD4/CD8 ratio, ο οποίος, σύμφωνα με τη σύγχρονη ιατρική βιβλιογραφία, συνιστά ισχυρότερο δείκτη ανοσολογικής γήρανσης και εξέλιξης της νόσου από ό,τι οι μεμονωμένες τιμές των CD4 ή CD8.